Rapor 1 — Öğrenme Süreci ve Zorunlu Deney Analizi

Reyhan Onbaşı | Öğrenci No: 202612696008 | YSA F26

1. Problem ve veri kümesi

El yazısı rakamların sınıflandırılması, düşük çözünürlüklü görüntülerde örüntü tanımanın temel bir örneğidir. Aynı rakam farklı kişiler tarafından farklı kalınlık, açı ve eğrilikte yazılabilir. Bu çeşitlilik nedeniyle sayısal piksel benzerliğine dayanan bir yöntem her zaman yeterli olmayabilir. Bu çalışmada geleneksel makine öğrenmesi sınıflandırıcıları ile evrişimsel sinir ağı yaklaşımı aynı veri bölünmesi üzerinde karşılaştırılmıştır. Temel amaç yalnızca yüksek bir başarı değeri bildirmek değil, doğrulama temelli model seçimi ile bağımsız test değerlendirmesini birbirinden ayırmaktır.

Çalışmanın veri kaynağı scikit-learn Digits veri kümesidir. Toplam 1.797 gözlem, 0 ile 9 arasındaki on sınıfa aittir ve her örnek 8 × 8 pikselden oluşur. Piksel değerleri 0–16 aralığındadır. Geleneksel algoritmalar için görüntüler 64 özellikli vektörlere dönüştürülürken CNN için iki boyutlu görüntü yapısı korunmuştur. Bu farklı gösterim biçimleri, algoritmaların veri yapısına uygun öğrenme özelliklerini değerlendirmek için kullanılmıştır.

Deney arşivindeki ayrım 1.257 eğitim, 270 doğrulama ve 270 test örneğinden oluşur. Test kümesinin model seçimine katılmaması, raporlanan başarının iyimserlik yanlılığını azaltmak için önemlidir. Kayıtlı çıktıların incelenmesi sonucunda birden fazla klasik sınıflandırıcı ve yapay sinir ağı ailesi karşılaştırılmış; sonradan ayrıca sabit veri ayrımı altında beş farklı rastgele başlangıçla CNN kararlılık deneyi yürütülmüştür. Bu ek deney farklı test kümelerini değil, aynı ayrım koşulunda eğitim rastgeleliğinin etkisini inceler.

2. Keşif, ön işleme ve veri ayrımı

Ön işleme aşamasında görüntülerin ölçüm aralığı ve algoritmaların beklediği girdi biçimi dikkate alınmıştır. CNN deneyinde piksel değerleri 16'ya bölünerek [0,1] aralığına ölçeklenmiş ve her görüntü (8,8,1) tensörüne dönüştürülmüştür. Bu dönüşüm veri kümesinin bilinen sabit piksel aralığına dayandığından öğrenilmiş bir test istatistiği içermez. Klasik yöntemlerde eğitim verisinden öğrenilmesi gereken dönüşümler varsa bunların yalnızca eğitim kümesi üzerinde fit edilmesi gerekir; her model için arşivdeki işlem hattı ayrıca kontrol edilmelidir.

3. Karşılaştırılan algoritmalar

Özgün deney kapsamında Logistic Regression, RBF çekirdekli SVM, Random Forest, KNN, Gradient Boosting ve sinir ağı modelleri değerlendirilmiştir. Bu algoritmalar farklı öğrenme varsayımlarını temsil eder: doğrusal karar sınırları, çekirdek yöntemleri, komşuluk benzerliği, ağaç toplulukları ve öğrenilen görüntü temsilleri. Yöntemlerin yalnızca hiperparametre sürümleri birbirinden bağımsız algoritma olarak sayılmamıştır.

CNN-C modeli 32 filtreli iki evrişim katmanı, batch normalization, havuzlama, dropout, 64 filtreli bir ek evrişim, global ortalama havuzlama ve yoğun katmanlar içerir. Dropout oranı 0,30, L2 katsayısı 0,0001, Adam öğrenme oranı 0,001 ve minibatch büyüklüğü 32 olarak kaydedilmiştir. Derin ağın nihai sınıflandırma katmanı 10 çıkışlı softmax yapısıdır. Kayıtlı mimarinin toplam parametre sayısı 33.002'dir.

4. Model eğitimi ve model seçimi

Ana deneyde model seçimi doğrulama performansına dayandırılmıştır. Beş-seed ek deneyde her koşu için en düşük doğrulama kaybındaki ağırlıklar tutulmuş, erken durdurma yaklaşımı kullanılmıştır. Eğitim en fazla 250 epoch olarak planlanmasına rağmen en uygun kayıt noktası koşuya göre değişmiştir. Böylece tek bir rastgele başlangıca bağımlı performans bildirme sorunu azaltılmaya çalışılmıştır.

Doğruluk, tüm gözlemler içinde doğru tahminlerin payını gösterir. Macro F1 ise her sınıfın F1 skorunu eşit ağırlıkla ortalayarak sınıf bazlı performans dengesini daha iyi görünür kılar. ROC-AUC, tek eşik üzerinden verilen kararların ötesinde ayrıştırma başarısını özetler. Model karşılaştırmasında doğrulama ve test sonuçlarını ayrı göstermek gereklidir; test kümesinden öğrendikten sonra yeni denemeler tasarlamak bilimsel olarak ek seçim yanlılığı doğurabilir.

5. Bulgular ve karşılaştırma

Ana deneyde doğrulama doğruluğu en yüksek model CNN-C iken test doğruluğunda SVM'nin küçük bir üstünlüğü vardır. Bu durum çelişki değildir; doğrulama ve test verileri sınırlı sayıda farklı örnek içerir. Testte SVM 267, CNN 265 örneği doğru sınıflandırmıştır. İki tahminlik fark tek başına model kalitesindeki kalıcı bir ayrımı göstermeyebilir. Arşivdeki eşleştirilmiş McNemar testinin p değeri 0,6875 olduğundan üstünlük için yeterli istatistiksel kanıt bulunmamaktadır.

Ek beş-seed deneyinde test doğruluğunun ortalaması %99,259, standart sapması yaklaşık 0,262 yüzde puandır. Eğitimlerin en düşük ve en yüksek test doğruluğu sırasıyla %98,889 ve %99,630 olmuştur. Beş sonuç birbirine yakın olduğundan sabit veri ayrımında rastgele başlangıç kaynaklı değişimin sınırlı olduğu görülür. Ancak farklı veri ayrımları yapılmadığı için bu değer güven aralığı veya bağımsız veri kümesi genelleme tahmini olarak okunmamalıdır.

Overfitting değerlendirmesinde yalnızca test doğruluğuna bakmak yeterli değildir. Ana deneyde CNN'nin eğitim doğruluğu %100 ve doğrulama doğruluğu yaklaşık %99,259 olduğundan gözlenen fark yaklaşık 0,741 yüzde puandır. Bu küçük fark olumlu görünse de eğitim ve doğrulama loss eğrileri birlikte incelenmelidir. Kararlılık deneyinde doğrulama kaybının daha sonra artabilmesi nedeniyle erken durdurma ve doğrulama kaybı ölçütüne göre ağırlıkların geri yüklenmesi kritik rol oynar.

6. Sınırlılıklar

Bu araştırma küçük, standartlaştırılmış ve düşük çözünürlüklü bir veri kümesine dayanır. Gerçek dünya el yazısı fotoğraflarında ışık, arka plan, farklı görüntü çözünürlükleri ve dağılım kayması görülebilir. Dolayısıyla bildirilen yüksek doğruluk, gerçek hayattaki tüm el yazısı uygulamalarına doğrudan genellenemez. Ayrıca beş-seed deneyinden önce test sonuçlarının görülmüş olması, en iyi görünen yeni koşuyu bilimsel yöntem üstünlüğü olarak seçmeyi sakıncalı kılar.

7. Model performans tablosu

Model	Dogrulama %	Test %	Macro F1 %
CNN (CNN-C Görüntü modeli)	99.259	98.148	98.124
Logistic Regression	97.778	98.519	98.516

SVM (RBF)	97.407	98.889	98.885
Random Forest	96.667	97.407	97.379
KNN	96.296	98.148	98.146
Gradient Boosting	95.185	96.296	96.271

8. CNN kararlılık analizi

Seed	En iyi epoch	Test %	Hata
101	34	98.889	3
202	37	99.630	1
303	31	99.259	2
404	23	99.259	2
505	50	99.259	2

9. Bu çalışmadan ne öğrendim?

Model seçimi ile test raporlamasının farklı aşamalar olması gerektiğini öğrendim. Doğrulamada yüksek çıkan modelin testte her zaman en yüksek skoru vermeyebileceğini somut olarak gördüm.

Özellikle küçük test kümelerinde birkaç tahminlik farkın yüzde değerini değiştirebildiğini ve bu farkın istatistiksel sınamayla yorumlanması gerektiğini öğrendim.

CNN eğitiminde dropout, L2 ve erken durdurmanın tek başına overfitting yokluğunu kanıtlamadığını; öğrenme eğrileriyle desteklenmesi gerektiğini öğrendim.

Yapay zekâ kullanımı beyanı

Bu çalışmada yapay zekâ araçlarından kodun gözden geçirilmesi, sonuçların düzenlenmesi, dil ve rapor taslağı oluşturulması amacıyla yararlanılmıştır. Sayısal sonuçlar çalıştırılan deney arşivlerinden alınmıştır. Nihai metin, kaynaklar ve kodun işleyişi teslim öncesinde öğrenci tarafından kontrol edilmeli ve kullanılan araçlar ile kullanım kapsamı gerektiğinde ayrıntılandırılmalıdır.

Kod ve veri bağlantıları

Veri kümesi: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html

GitHub kod deposu: https://github.com/ReyhanOnbasi/El-Yazisi-Rakam-Siniflandirma