# Rapor 1 — Öğrenme Süreci ve Zorunlu Deney Analizi

Reyhan Onbaşı | Öğrenci No: 202612696008 | YSA F26

## 1. Problem ve veri kümesi

El yazısı rakamların sınıflandırılması, düşük çözünürlüklü görüntülerde örüntü tanımanın temel bir örneğidir. Aynı rakam farklı kişiler tarafından farklı kalınlık, açı ve eğrilikte yazılabilir. Bu çeşitlilik nedeniyle sayısal piksel benzerliğine dayanan bir yöntem her zaman yeterli olmayabilir. Bu çalışmada geleneksel makine öğrenmesi sınıflandırıcıları ile evrişimsel sinir ağı yaklaşımı aynı veri bölünmesi üzerinde karşılaştırılmıştır. Temel amaç yalnızca yüksek bir başarı değeri bildirmek değil, doğrulama temelli model seçimi ile bağımsız test değerlendirmesini birbirinden ayırmaktır.

Çalışmanın veri kaynağı scikit-learn Digits veri kümesidir. Toplam 1.797 gözlem, 0 ile 9 arasındaki on sınıfa aittir ve her örnek 8 × 8 pikselden oluşur. Piksel değerleri 0–16 aralığındadır. Geleneksel algoritmalar için görüntüler 64 özellikli vektörlere dönüştürülürken CNN için iki boyutlu görüntü yapısı korunmuştur. Bu farklı gösterim biçimleri, algoritmaların veri yapısına uygun öğrenme özelliklerini değerlendirmek için kullanılmıştır.

Colab'ın 17 Ekim 2026 tarihli tek çalışma oturumunda 1.797 örnek, sınıf oranları korunarak 1.257 eğitim, 270 doğrulama ve 270 test örneğine ayrılmıştır. Ayrım indeksleri kaydedilmiş ve kümeler arasında kesişim olmadığı doğrulanmıştır. Ana model doğrulama makro F1 ölçütüyle, test kümesine bakılmadan seçilmiştir. Aynı veri ayrımı, beş başlangıç tohumu ve üç mimarinin üçer tekrarı için de korunmuştur.

## 2. Keşif, ön işleme ve veri ayrımı

Ön işleme, her algoritmanın giriş beklentisine göre düzenlenmiştir. CNN için piksellerin bilinen 0–16 ölçüm aralığı 16'ya bölünerek [0,1] aralığına taşınmış, görüntüler (8, 8, 1) biçimine getirilmiştir. Bu sabit dönüşüm test kümesinin ortalamasını ya da varyansını öğrenmez. Klasik yöntemlerde görüntüler 64 özellikli vektör olarak kullanılmıştır. Lojistik regresyon, KNN ve RBF-SVM için StandardScaler ve sınıflandırıcı aynı scikit-learn Pipeline içinde yer alır. Böylece GridSearchCV'nin her çapraz doğrulama katında ölçekleyici yalnızca o katın eğitim örneklerinden öğrenilir; doğrulama ve test örneklerinden öğrenilmiş istatistik alınmaz. Random Forest ve HistGradientBoostingClassifier için ölçeklendirme uygulanmamıştır; bu ağaç tabanlı yöntemler burada zorunlu bir standartlaştırmaya ihtiyaç duymamaktadır. Beş farklı algoritmanın hiperparametreleri StratifiedKFold ile beş katlı çapraz doğrulama kullanılarak yalnızca X_train ve y_train üzerinde aranmıştır. Test bölümü hiçbir hiperparametre seçim adımına katılmamıştır.

## 3. Karşılaştırılan algoritmalar

Özgün deney kapsamında Logistic Regression, RBF çekirdekli SVM, Random Forest, KNN, Gradient Boosting ve sinir ağı modelleri değerlendirilmiştir. Bu algoritmalar farklı öğrenme varsayımlarını temsil eder: doğrusal karar sınırları, çekirdek yöntemleri, komşuluk benzerliği, ağaç toplulukları ve öğrenilen görüntü temsilleri. Yöntemlerin yalnızca hiperparametre sürümleri birbirinden bağımsız algoritma olarak sayılmamıştır.

CNN-C modeli 32 filtreli iki evrişim katmanı, batch normalization, havuzlama, dropout, 64 filtreli bir ek evrişim, global ortalama havuzlama ve yoğun katmanlar içerir. Dropout oranı 0,30, L2 katsayısı 0,0001, Adam öğrenme oranı 0,001 ve minibatch büyüklüğü 32 olarak kaydedilmiştir. Derin ağın nihai sınıflandırma katmanı 10 çıkışlı softmax yapısıdır. Kayıtlı mimarinin toplam parametre sayısı 33.002'dir.

## 4. Model eğitimi ve model seçimi

Ana deneyde klasik modeller eğitim kümesi içinde çapraz doğrulamayla ayarlanırken MLP-A, MLP-B ve CNN-C için doğrulama performansına göre erken durdurma uygulanmıştır. MLP-A 43, MLP-B 238, CNN-C ise 46 epoch çalışmış; CNN-C için en iyi epoch 28 olarak kaydedilmiştir. Beş tohumlu kararlılık analizinde ağ her koşuda sıfırdan kurulmuş, en düşük doğrulama kaybı ile ağırlıklar geri yüklenmiştir. Ek dokuz eğitim test kümesinde yeni bir model seçimi amacıyla kullanılmamıştır.

Doğruluk, tüm gözlemler içinde doğru tahminlerin payını gösterir. Macro F1 ise her sınıfın F1 skorunu eşit ağırlıkla ortalayarak sınıf bazlı performans dengesini daha iyi görünür kılar. ROC-AUC, tek eşik üzerinden verilen kararların ötesinde ayrıştırma başarısını özetler. Model karşılaştırmasında doğrulama ve test sonuçlarını ayrı göstermek gereklidir; test kümesinden öğrendikten sonra yeni denemeler tasarlamak bilimsel olarak ek seçim yanlılığı doğurabilir.

## 5. Bulgular ve karşılaştırma

Colab ana deneyinde doğrulama makro F1 bakımından CNN-C (0,99266) seçilmiştir. Bağımsız testte CNN-C 270 örneğin 265'ini (%98,15), SVM-RBF ise 267'sini (%98,89) doğru sınıflandırmıştır. İki örneklik fark, kesin McNemar testinde istatistiksel olarak anlamlı bir üstünlük göstermemektedir (p=0,6875). CNN-C için test makro F1 değeri 0,98124, SVM-RBF için 0,98885 olmuştur.

Colab'da 101, 202, 303, 404 ve 505 tohumları ile yapılan beş CNN-C eğitiminin test doğrulukları sırasıyla %98,15, %99,63, %97,04, %99,63 ve %99,26'dır. Ortalama %98,74, örnek standart sapması yaklaşık 1,13 yüzde puandır. En düşük skor 303, en yüksek skor 202 ve 404 koşularında görülmüştür. Bu sonuç, aynı veri ayrımında bile eğitim rastgeleliğinin göz ardı edilemeyeceğini gösterir. Bunlar bağımsız yeni test kümeleri değil, aynı 270 örnek üstündeki keşifsel tekrarlardır.

Aşırı öğrenmeyi değerlendirmek için eğitim, doğrulama ve test ölçütleri birlikte incelenmiştir. Ana deneyde CNN-C'nin eğitim doğruluğu %100, doğrulama doğruluğu %99,26 olduğundan eğitim-doğrulama farkı yaklaşık 0,74 yüzde puandır. Bu fark tek başına aşırı öğrenme olmadığı anlamına gelmez; doğrulama kaybının seyrine, erken durdurmaya ve farklı başlangıçlarda elde edilen değişkenliğe de bakılmalıdır. Ek dokuz eğitimde güçlü düzenlileştirmenin ortalama doğrulama kaybı 0,02876, referansın 0,02909'dur; bu küçük farkın kesin üstünlük sayılmaması gerekir.

## 6. Sınırlılıklar

Veri kümesi küçük, temiz ve 8 × 8 çözünürlüklü olduğundan sonuçlar kamera fotoğrafları, farklı ışık koşulları veya farklı kişilerin el yazıları için doğrudan genellenemez. Beş kararlılık koşusu aynı test kümesini tekrar kullanır ve test sonuçları görüldükten sonra yürütüldüğünden bağımsız bir dış doğrulama değildir. Farklı veri ayrımları, yazara göre grup bazlı değerlendirme ve yeni bir test kümesi ile genellenebilirlik ayrıca araştırılmalıdır.

## 7. Model performans tablosu (Colab ana deney)

**Tablo 1. Modellerin karşılaştırmalı sonuçları**

| Model | Dogrulama % | Test % | Macro F1 % |
|---|---|---|---|
| CNN (CNN-C Görüntü modeli) | 99.26 | 98.15 | 98.12 |
| Logistic Regression | 97.78 | 98.52 | 98.52 |
| SVM (RBF) | 97.41 | 98.89 | 98.88 |
| Random Forest | 96.67 | 97.41 | 97.38 |
| KNN | 96.30 | 98.15 | 98.15 |
| Gradient Boosting | 95.19 | 96.30 | 96.27 |

## 8. CNN kararlılık analizi (Colab, beş tohum)

**Tablo 2. CNN-C kararlılık analizi**

| Seed | En iyi epoch | Test % | Hata |
|---|---|---|---|
| 101 | 44 | 98.15 | 5 |
| 202 | 37 | 99.63 | 1 |
| 303 | 31 | 97.04 | 8 |
| 404 | 23 | 99.63 | 1 |
| 505 | 50 | 99.26 | 2 |

## 9. Bu çalışmadan ne öğrendim?

Model seçimi ile test raporlamasının iki ayrı aşama olduğunu öğrendim. Bir modeli doğrulama makro F1 değerine göre seçmek, onun testte de en yüksek doğruluğu elde edeceğini garanti etmiyor: CNN-C doğrulamada ilk sıradayken SVM testte iki gözlem daha fazla doğru tahmin yaptı. Böyle bir durumda test sonuçlarını gördükten sonra model seçim kuralını değiştirmek yanıltıcı olur. Ayrıca Pipeline içinde yapılan ölçeklendirmenin, çapraz doğrulama katlarının dışındaki örneklerin bilgilerini eğitim sürecine taşımamayı sağladığını öğrendim.

270 test örneği üzerinde tek bir farklı tahminin yaklaşık 0,37 yüzde puanlık doğruluğa karşılık geldiğini öğrendim. Bu nedenle küçük veri kümelerinde yalnızca yüzdeye bakarak 'daha iyi model' demek doğru değil. Eşleştirilmiş McNemar karşılaştırmasındaki p=0,6875 değeri de iki modelden birinin istatistiksel olarak üstün olduğunu göstermeye yetmedi. Öğrendiğim diğer nokta, modelin eğitim doğruluğunun %100 olmasının tek başına güvenilir genelleme kanıtı olmadığı; eğitim, doğrulama ve test davranışlarının birlikte yorumlanması gerektiğidir.

Dropout, L2 ve erken durdurmanın aşırı uyumu kontrol etmeye çalıştığını; birden fazla başlangıç tohumu denemenin ise aynı modelin eğitim rastgeleliğine duyarlılığını değerlendirdiğini öğrendim. CNN-C'nin aynı test kümesinde beş eğitimde %97,04–%99,63 arasında değişmesi, tek bir koşuyu modelin değişmez başarısı gibi sunmamam gerektiğini gösterdi. Kararlılık denemelerinin aynı test gözlemlerini tekrar kullandığını, yeni bir dış test kümesinin yerini tutmadığını da öğrendim. Bundan sonraki çalışma için en sağlam adımın daha büyük ve bağımsız veriyle doğrulama olduğunu düşünüyorum.

## Yapay zekâ kullanımı beyanı

Bu çalışmada üretken yapay zekâdan kod taslağı ve düzenleme, hata giderme, sonuç kontrolü, rapor planlama ve dil düzenlemesi için yararlanılmıştır. Eğitimler Google Colab'da yürütülmüş; tablolar, grafikler ve deney yorumları kaydedilmiş çıktı dosyalarına dayandırılmıştır. Kullanılan kaynakların doğruluğu, kullanılan kodun anlaşılması ve nihai teslimin akademik sorumluluğu öğrenciye aittir.

## Kod ve veri bağlantıları

Veri kümesi: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html

GitHub kod deposu: https://github.com/ReyhanOnbasi/El-Yazisi-Rakam-Siniflandirma