Rapor 2 — Akademik Makale: Digits Veri Kümesinde Sınıflandırıcıların Karşılaştırılması

Reyhan Onbaşı | Öğrenci No: 202612696008 | YSA F26

Özet

Bu çalışmada scikit-learn Digits veri kümesindeki el yazısı rakamların sınıflandırılması için beş klasik makine öğrenmesi algoritma ailesi ile çok katmanlı algılayıcı (MLP) ve evrişimsel sinir ağı (CNN) yapılandırmaları karşılaştırılmıştır. Toplam 1.797 adet 8 × 8 gri tonlu görüntü, sınıf dağılımı korunarak 1.257 eğitim, 270 doğrulama ve 270 test örneğine ayrılmıştır. Klasik yöntemlerin hiperparametreleri eğitim kümesindeki çapraz doğrulamayla ayarlanmış, sinir ağlarında dropout, L2 düzenlileştirme ve erken durdurma kullanılmıştır. Model seçimi bağımsız test sonuçları görülmeden doğrulama makro F1 ölçütüne göre yapılmıştır. Bu ölçütte CNN-C 0,99266 değerine ulaşarak seçilmiş, test kümesinde %98,15 doğruluk ve 0,98124 makro F1 elde etmiştir. RBF çekirdekli destek vektör makinesi testte %98,89 doğruluk üretmiş; iki yöntemin toplam doğru tahmin sayısı arasındaki fark yalnızca iki örnek olmuştur. Kesin McNemar testi bu fark için istatistiksel açıdan yeterli üstünlük kanıtı göstermemiştir (p=0,6875). Ayrıca CNN mimarisinin beş farklı rastgele başlangıç altındaki eğitim kararlılığı ve kapasite ile düzenlileştirme seçeneklerinin doğrulama performansı incelenmiştir. Bulgular, küçük görüntü veri kümelerinde klasik sınıflandırıcıların güçlü karşılaştırma yöntemleri olduğunu ve model seçiminde doğrulama-test ayrımının korunması gerektiğini göstermektedir. Sonradan yapılan ek deneyler, yeni bir bağımsız test doğrulaması olarak yorumlanmamıştır.

1. Giriş

El yazısı rakamların sınıflandırılması, düşük çözünürlüklü görüntülerde örüntü tanımanın temel bir örneğidir. Aynı rakam farklı kişiler tarafından farklı kalınlık, açı ve eğrilikte yazılabilir. Bu çeşitlilik nedeniyle sayısal piksel benzerliğine dayanan bir yöntem her zaman yeterli olmayabilir. Bu çalışmada geleneksel makine öğrenmesi sınıflandırıcıları ile evrişimsel sinir ağı yaklaşımı aynı veri bölünmesi üzerinde karşılaştırılmıştır. Temel amaç yalnızca yüksek bir başarı değeri bildirmek değil, doğrulama temelli model seçimi ile bağımsız test değerlendirmesini birbirinden ayırmaktır. [1]

Çalışmanın veri kaynağı scikit-learn Digits veri kümesidir. Toplam 1.797 gözlem, 0 ile 9 arasındaki on sınıfa aittir ve her örnek 8 × 8 pikselden oluşur. Piksel değerleri 0–16 aralığındadır. Geleneksel algoritmalar için görüntüler 64 özellikli vektörlere dönüştürülürken CNN için iki boyutlu görüntü yapısı korunmuştur. Bu farklı gösterim biçimleri, algoritmaların veri yapısına uygun öğrenme özelliklerini değerlendirmek için kullanılmıştır. [2]

Deney arşivindeki ayrım 1.257 eğitim, 270 doğrulama ve 270 test örneğinden oluşur. Test kümesinin model seçimine katılmaması, raporlanan başarının iyimserlik yanlılığını azaltmak için önemlidir. Kayıtlı çıktıların incelenmesi sonucunda birden fazla klasik sınıflandırıcı ve yapay sinir ağı ailesi karşılaştırılmış; sonradan ayrıca sabit veri ayrımı altında beş farklı rastgele başlangıçla CNN kararlılık deneyi yürütülmüştür. Bu ek deney farklı test kümelerini değil, aynı ayrım koşulunda eğitim rastgeleliğinin etkisini inceler. [20]

Küçük görüntü veri kümelerindeki değerlendirmelerin özel bir güçlüğü vardır. Test kümesindeki tek bir hatalı tahmin, yüzdelik başarı değerini anlamlı görünen miktarda değiştirebilir. Bu nedenle yüzdelik başarıların basamak sayısı, belirsizliğin olduğundan daha düşük görünmesine neden olmamalıdır. Buradaki test kümesinde 270 gözlem vardır; tek bir gözlemin doğruluk üzerindeki etkisi yaklaşık 0,370

yüzde puandır. İki model arasındaki birkaç tahminlik farkı yöntem üstünlüğü olarak yorumlamak için eşleştirilmiş karşılaştırmanın sonuçları ayrıca değerlendirilmelidir. [19]

Modelin eğitime uyum sağlaması ile daha önce görmediği verilerdeki başarısı birbirinden ayrılmalıdır. Eğitim verisi üzerinde elde edilen çok yüksek doğruluk, temsil kapasitesi yüksek bir modelin örnekleri ezberlemiş olabileceği ihtimalini dışlamaz. Doğrulama kümesi eğitim sürecindeki kararların verilmesini, test kümesi ise bu kararlar sabitlendikten sonra nihai performansın değerlendirilmesini sağlar. Bu iki rolün karıştırılması, ölçülen başarının gerçeği olduğundan yüksek göstermesine neden olabilir. [20]

Bu araştırma özellikle yorumlanabilir deney tasarımını ön plana çıkarır. Karşılaştırılan yöntemlerin farklı algoritma ailelerinden seçilmesi, tek bir mimariyi farklı sayıda katmanla tekrar tekrar eğitmekten daha geniş bir karşılaştırma üretir. Aynı zamanda tek bir modelin birden fazla rastgele başlangıçla çalıştırılması, farklı bir araştırma sorusuna cevap verir: sabit veri ayrımı ve mimari altında eğitimin başlangıç koşullarına duyarlılığı. Bu iki sorunun aynı tabloda karıştırılmaması gerekir.

Çalışmanın ikinci katkısı, model karşılaştırmasını yalnızca en yüksek sonucu bulma çabasına indirgememesidir. Ana deney doğrulama temelli seçimin sonuçlarını gösterirken ek CNN çalışması beş farklı başlangıcın ortalamasını ve değişkenliğini sunar. Bu düzen, modelin davranışındaki küçük değişimlerin ne kadar önemli olduğuna ilişkin daha ihtiyatlı bir yorum sağlar. Bulguların kendi deney koşullarının sınırları içinde değerlendirilmesi, sonucun gerçek dünya uygulamaları için ne anlama geldiğini daha açık hâle getirir.

Bu yönüyle çalışmanın araştırma sorusu iki katmanlıdır: farklı algoritmaların sabit koşullardaki göreli performansı ve seçilmiş CNN mimarisinin eğitim rastgeleliğine duyarlılığı. Raporun yöntem ve sonuç bölümleri bu iki soruyu birbirinden ayrı tanımlar. Karşılaştırmanın amacı üretim ortamında kesin performans iddiasında bulunmak değil, deney protokolünün gerektirdiği kanıtları adım adım sunmaktır.

Bu çalışmanın temel araştırma sorusu, aynı veri bölünmesiyle değerlendirilen farklı öğrenme yaklaşımlarının başarı farklarının nasıl yorumlanacağıdır. Özellikle test kümesindeki birkaç örneğin değişmesinin doğruluk yüzdesini belirgin biçimde etkileyebileceği dikkate alınmıştır. Bu nedenle yalnızca en yüksek puanın raporlanması yerine doğrulama ile test sonuçları ayrı tutulmuş, modellerin ortak ve farklı hataları incelenmiş ve CNN için farklı başlangıç koşullarında elde edilen sonuçlar birlikte değerlendirilmiştir.

2. Literatür Taraması

LeCun ve çalışma arkadaşlarının 1998 tarihli doküman tanıma araştırması, piksellerin yerel komşuluk yapısını kullanan evrişimsel ağların görüntü sınıflandırma açısından önemini göstermiştir. Bu yaklaşım, düzleştirilmiş vektör üzerinde çalışan klasik sınıflandırıcılardan farklı bir temsil öğrenme mekanizmasına dayanır. Buradaki CNN-C deneyinin kavramsal temeli de yerel filtreleme, özellik hiyerarşisi ve sınıflandırma katmanlarının birlikte öğrenilmesidir. [1]

Cortes ve Vapnik tarafından sunulan destek vektör makineleri sınıflar arasındaki ayrımı marjini artırarak sağlamayı hedefler. RBF çekirdeği doğrusal olmayan ilişkileri yakalamayı kolaylaştırır. Bu veri kümesinde SVM yönteminin güçlü olması, boyutu görece küçük ve iyi düzenlenmiş piksellerden oluşturulan örneklerde çekirdek tabanlı karar sınırlarının başarılı olabileceği beklentisiyle uyumludur. [3]

Breiman'ın Random Forest yaklaşımı çok sayıda karar ağacından elde edilen tahminleri birleştirir. Friedman'ın Gradient Boosting yöntemi ise ardışık zayıf öğrenicilerin hatalarını azaltmayı hedefleyen topluluk yaklaşımıdır. İki yöntemin tek bir ağaçtan farklı olarak tahmin varyansını ve yanlılığı yönetme biçimleri, görüntü verisi üzerindeki farklı sonuçları yorumlamak için önemlidir. [4,5]

Cover ve Hart tarafından incelenen en yakın komşu sınıflandırması eğitim verisine olan uzaklığa dayalı basit ama etkili bir temel yöntem sağlar. Lojistik regresyon ise karar fonksiyonunun girdilerle ilişkisini doğrusal parametrelerle ifade eder. Bu çalışmada farklı algoritma ailelerini bir arada değerlendirmek, başarıyı yalnızca sinir ağı mimarisine bağlamadan yorumlayabilmek için önemlidir. [6,7]

Rumelhart ve arkadaşlarının geri yayılım yaklaşımı öğrenilebilir ağırlıkların kayıp gradyanıyla güncellenmesini açıklamıştır. Daha sonra büyük ölçekli görüntü sınıflandırması için derin evrişimsel ağların kullanımı Krizhevsky ve arkadaşlarının ImageNet çalışmasıyla önemli bir görünürlük kazanmıştır. Ancak büyük veri üzerinde kurulmuş başarı beklentilerini doğrudan 1.797 örnekli Digits kümesine aktarmak mümkün değildir. [8,9]

Srivastava ve arkadaşlarının dropout yöntemi eğitim sırasında bazı bağlantıları geçici olarak etkin dışı bırakıp eş-uyum riskini azaltır. Ioffe ve Szegedy'nin batch normalization yöntemi eğitim davranışını düzenler; Kingma ve Ba tarafından geliştirilen Adam optimizasyonu gradyan temelli güncellemeleri adaptif hâle getirir. Bu yöntemlerin bir arada bulunması, doğrulama eğrilerinin yorumlanmasını gereksiz kılmaz. [10,11,12]

Kohavi'nin çapraz doğrulama ve bootstrap karşılaştırmaları model değerlendirme yönteminin önemini vurgular. Cawley ve Talbot, model seçiminin kendisinin de aşırı uyum yaratabileceğine dikkat çeker. Varoquaux ise küçük örneklem koşullarındaki geniş belirsizlik aralıklarının altını çizmiştir. Böylece bu projedeki yüksek yüzde değerleri, özellikle çok sayıda tekrar deneme yapıldığında dikkatle değerlendirilmelidir. [13,19,20]

Dietterich'in sınıflandırıcı karşılaştırmaları üzerine değerlendirmesi ve McNemar'ın eşleştirilmiş oranlar testi, aynı test gözlemlerinde oluşan farklılıkların yalnızca çıplak doğruluk puanıyla sınırlı kalmaması gerektiğini gösterir. Efron ve Tibshirani tarafından sistemleştirilen bootstrap yöntemleri ise karşılaştırmadaki belirsizliği örnekleme yoluyla ifade etmeye yardımcı olur. [14,15,16]

Sokolova ve Lapalme sınıflandırma metriklerinin farklı özelliklerini sistematik biçimde tartışmıştır. Fawcett, ROC eğrisinin model başarısını farklı karar eşiklerinde değerlendirme amacıyla kullanılabileceğini göstermiştir. Bu projede accuracy yanında Macro F1 ve ROC-AUC sunulması, ölçümün tek sayıya indirgenmemesi için tercih edilmiştir. [17,18]

Pedregosa ve arkadaşlarının scikit-learn yazılımına ilişkin çalışması, çok sayıda algoritmanın ortak API ile karşılaştırılmasını mümkün kılan bir uygulama zemini sunar. TensorFlow yazılımının büyük ölçekli öğrenme altyapısı ile PyTorch üzerine gerçekleştirilen çalışma, derin öğrenmede kullanılan iki farklı yazılım ekosistemini örneklemektedir. Bu deneylerde TensorFlow kullanılmıştır; PyTorch ile ayrı bir uygulama gerçekleştirilmemiştir. Kullanılan yazılım ve paket sürümlerini raporlamak, bir deneyin tekrar üretilebilmesine yardımcı olur. [2,21,22]

Sınıflandırma literatüründe sık karşılaşılan bir sorun, farklı veri kümeleri ve farklı test koşulları altında raporlanan doğrulukların doğrudan karşılaştırılmasıdır. Oysa aynı algoritma uygulamasının farklı ayrımlarda veya farklı ön işleme tercihleriyle farklı performans göstermesi mümkündür. Bu nedenle deneysel çalışmalarda veri bölünmesi, veri dönüşümleri, model seçimi ve kullanılan metrikler şeffaf biçimde belgelenmelidir. Eğitim boyunca test kümesinden gelen sinyallerin karar mekanizmasına karışmaması bu belgelemenin en önemli parçasıdır. [13,20]

Evrişimsel ağların güçlü yönlerinden biri, komşu pikseller arasındaki yerel örüntüleri filtreler aracılığıyla temsil edebilmesidir. Bununla birlikte yalnızca sekiz piksel genişliğinde görüntülerde derinlik ve havuzlama tercihleri farklı sonuçlara yol açabilir. Küçük görüntüler için daha büyük ağın otomatik olarak daha başarılı olacağı söylenemez. Regularization, model kapasitesi, öğrenme hızı ve veri miktarı birlikte değerlendirilmelidir. Bu bakımdan CNN-C mimarisi için kaydedilmiş parametreler, sonraki çalışmaların karşılaştırılabilirliğini sağlar. [1,10]

Performans ölçümleri konusu literatürde merkezi bir yer tutar. Accuracy dengeli kümelerde kolay yorumlanabilir, fakat tek başına hangi sınıfların daha zor olduğunu göstermeyebilir. Sınıf başına precision ve recall, belirli rakamların karıştırılmasını incelemek için yararlıdır. Macro F1'in her sınıfa eşit ağırlık vermesi, performansı yalnızca örnek sayısı yüksek sınıfların belirlemesini engeller. Çok sınıflı ROC-AUC ise modelin olasılıksal ayrıştırma davranışına başka bir bakış sunar. [17,18]

Çok sayıda deneme yapılan projelerde model seçiminin test verisine dolaylı uyum sağlama tehlikesi vardır. Bir araştırmacı test sonucunu inceledikten sonra tekrar tekrar yeni modeller dener ve sonunda en yüksek puanı raporlarsa, bu değer bağımsız değerlendirme özelliğini kısmen kaybetmiş olur. Cawley ve Talbot tarafından incelenen model seçim yanlılığı burada doğrudan önem taşır. Bu nedenle son deneylerin önceki test sonuçları görüldükten sonra yapıldığı açıkça belirtilmekte, nihai yorum ortalama ve sınırlar üzerinden kurulmaktadır. [20]

3. Materyal ve Yöntem

Ön işleme aşamasında görüntülerin ölçüm aralığı ve algoritmaların beklediği girdi biçimi dikkate alınmıştır. CNN deneyinde piksel değerleri 16'ya bölünerek [0,1] aralığına ölçeklenmiş ve her görüntü (8,8,1) tensörüne dönüştürülmüştür. Bu dönüşüm veri kümesinin bilinen sabit piksel aralığına dayandığından öğrenilmiş bir test istatistiği içermez. Klasik yöntemlerde eğitim verisinden öğrenilmesi gereken dönüşümler varsa bunların yalnızca eğitim kümesi üzerinde fit edilmesi gerekir; her model için arşivdeki işlem hattı ayrıca kontrol edilmelidir. [2]

Özgün deney kapsamında Logistic Regression, RBF çekirdekli SVM, Random Forest, KNN, Gradient Boosting ve sinir ağı modelleri değerlendirilmiştir. Bu algoritmalar farklı öğrenme varsayımlarını temsil eder: doğrusal karar sınırları, çekirdek yöntemleri, komşuluk benzerliği, ağaç toplulukları ve öğrenilen görüntü temsilleri. Yöntemlerin yalnızca hiperparametre sürümleri birbirinden bağımsız algoritma olarak sayılmamıştır.

CNN-C modeli 32 filtreli iki evrişim katmanı, batch normalization, havuzlama, dropout, 64 filtreli bir ek evrişim, global ortalama havuzlama ve yoğun katmanlar içerir. Dropout oranı 0,30, L2 katsayısı 0,0001, Adam öğrenme oranı 0,001 ve minibatch büyüklüğü 32 olarak kaydedilmiştir. Derin ağın nihai sınıflandırma katmanı 10 çıkışlı softmax yapısıdır. Kayıtlı mimarinin toplam parametre sayısı 33.002'dir.

Ana deneyde model seçimi doğrulama performansına dayandırılmıştır. Beş-seed ek deneyde her koşu için en düşük doğrulama kaybındaki ağırlıklar tutulmuş, erken durdurma yaklaşımı kullanılmıştır. Eğitim en fazla 250 epoch olarak planlanmasına rağmen en uygun kayıt noktası koşuya göre değişmiştir. Böylece tek bir rastgele başlangıca bağımlı performans bildirme sorunu azaltılmaya çalışılmıştır. [10]

Doğruluk, tüm gözlemler içinde doğru tahminlerin payını gösterir. Macro F1 ise her sınıfın F1 skorunu eşit ağırlıkla ortalayarak sınıf bazlı performans dengesini daha iyi görünür kılar. ROC-AUC, tek eşik üzerinden verilen kararların ötesinde ayrıştırma başarısını özetler. Model karşılaştırmasında doğrulama ve test sonuçlarını ayrı göstermek gereklidir; test kümesinden öğrendikten sonra yeni denemeler tasarlamak bilimsel olarak ek seçim yanlılığı doğurabilir. [17,18]

Veri bölünmesini korumak için ana deney arşivinde saklanan split_indices.npz dosyası kullanılmıştır. Eğitim, doğrulama ve test indekslerinin aynı örneği içermemesi, tüm indekslerin veri kümesinin sınırları içinde kalması ve birlikte 1.797 farklı gözlemi kapsaması kontrol edilmiştir. Bu ayrım, yeni CNN kararlılık deneyinin ana deneyle doğrudan karşılaştırılmasına yardımcı olur. Ayrımın sabit tutulması, koşular arasında veri örnekleme değişkenliğinin değil yalnızca eğitim rastgeleliğinin incelendiği anlamına gelir.

Sınıflandırıcıları karşılaştırırken algoritmanın girdiye ilişkin varsayımları da dikkate alınmıştır. KNN örnekler arasındaki uzaklık ilişkisini, SVM dönüştürülmüş özellik uzayındaki marjini, ağaç toplulukları

özelliklere dayalı bölme kurallarını ve CNN yerel uzamsal filtreleri kullanır. Bu farklılıklar, aynı veri bölünmesi üzerinde elde edilen sonuçların neden bire bir eşit olmayabileceğini açıklayan temel mekanizmalardır. Bu çalışmada temel değerlendirme, algoritmaların teorik üstünlüğüne değil söz konusu veri kümesindeki gözlenen davranışına odaklanmıştır.

Ölçekleme, özellik seçimi veya parametre ayarı eğitim örneklerinden öğreniliyorsa bu işlem test verisi kullanılarak gerçekleştirilmemelidir. Sabit bölünme sonrasında eğitim örnekleriyle fit edilen herhangi bir dönüşüm doğrulama ve test örneklerine yalnızca transform olarak uygulanmalıdır. scikit-learn Pipeline yaklaşımı bu işlem sırasını güvence altına almak için uygun bir araçtır. CNN'nin sabit 0–16 piksel aralığını 16'ya bölerek normalleştirmesi ise veri üzerinden tahmin edilen bir ölçek parametresi gerektirmez. [2]

Eğitim rastgeleliği; model ağırlıklarının başlangıç değerleri, mini-batch sıralaması ve bazı hesaplama işlemlerindeki deterministik olmayan davranışlardan etkilenebilir. Farklı seed değerleri bu kaynakların bir bölümünü kontrol etmeyi kolaylaştırır. Bununla birlikte farklı donanım, CUDA kütüphanesi veya makine öğrenmesi framework sürümü aynı seed altında tamamen aynı sayısal çıktıları garanti etmez. Bu nedenle çalışmanın çevre sürümleri ve kaynak dosyanın SHA-256 özeti ek deney arşivinde saklanmıştır.

Model seçimi doğrulama kaybının en düşük olduğu eğitim noktasına dayanır. Erken durdurma, uzun eğitim süreçlerinde doğrulama performansı kötüleşirken gereksiz epoch sayısını sınırlamaya yardımcı olur. En iyi ağırlıkların yeniden yüklenmesi, son epoch ağırlıklarının rastlantısal biçimde seçilmesini önler. Bu mekanizmaların birlikte kullanılması overfitting riskini azaltabilir; ancak test başarısı, doğrulama kaybı ve eğitim eğrilerinin incelenmesi hâlâ gereklidir.

Test performansını hesaplarken kullanılan bölünmenin değişmemesi özellikle önemlidir. Eğer modeller farklı test kümelerinde değerlendirilseydi aralarındaki küçük başarı farkları yöntem etkisi ile örnekleme etkisini aynı anda yansıtabilirdi. Burada aynı test gözlemleri üzerinde karşılaştırma yapılabildiğinden CNN–SVM çifti için eşleştirilmiş doğruluk durumu doğrudan analiz edilmiştir. McNemar testi, sadece toplam doğru sayılarından değil iki yöntemin aynı gözlemler üzerindeki uyuşmazlıklarından yararlanır. [15]

Veri bölünmesi hakkında raporlamanın amacı yalnızca toplam örnek sayısını bildirmek değildir. Aynı örneğin hem eğitim hem test kümesinde bulunmaması sağlanmalı, her bölünmedeki sınıf dağılımı makul düzeyde olmalıdır. Kayıtlı indeksler üzerinde yapılan bütünlük kontrolü, her gözlemin yalnızca bir bölünmede bulunduğunu doğrulamaktadır. Bu güvence yeni kararlılık deneyi için de önemlidir. Model aynı test kümesinde değerlendirildiğinden rastgeleliğin neden olduğu değişimler farklı test örneklerinin seçilmesiyle karıştırılmamaktadır. Bununla birlikte bir kişinin tüm örneklerini aynı bölünmede tutan grup tabanlı bir protokol uygulanıp uygulanmadığı mevcut arşivden doğrulanamaz.

Deney sonuçlarının hesaplanmasında etiket tahminleri ve tahmin olasılıkları farklı amaçlarla kullanılır. Doğruluk ve Macro F1 için her test örneğinin tahmin edilen sınıfı gerekirken ROC-AUC için sınıf olasılıklarının karşılaştırılması önemlidir. Bu nedenle model dosyalarının yanında tahmin CSV ve NumPy olasılık dosyalarının da saklanması, sonradan yapılan değerlendirmelerin yeniden üretilebilmesini sağlar. Farklı hesaplama kütüphanesi sürümleri küçük nümerik farklara yol açabildiğinden ortam bilgileri ayrıca korunmuştur. Bu yaklaşım, raporlanan bir yüzde değerinin kaynağını izlemeyi kolaylaştırır.

Klasik yöntemlerle CNN arasında eşit koşullar sağlanırken girdi biçimi zorunlu olarak farklılaşmaktadır. CNN görüntünün satır ve sütun düzenini korur; klasik sınıflandırıcıların çoğu ise tek boyutlu özellik vektörü bekler. Bu dönüşüm temel piksel bilgisini ortadan kaldırmaz, ancak uzamsal komşuluk ilişkilerinin açık biçimde işlenmesini değiştirir. Bu nedenle sonuçların tamamını yalnızca optimizasyon algoritmasına bağlamak doğru olmaz. Öğrenilen temsilin biçimi de değerlendirmeye dahil edilmelidir. Yöntemler bölümünde bu ayrımın belirtilmesi karşılaştırmanın kapsamını açıklaştırır.

Bir modelin kaydedilmiş ağırlıklarını yeniden yükleyerek tahmin elde etmek ile sıfırdan eğitimini tekrarlamak aynı şey değildir. Yeniden yükleme kayıtlı modelin değerlendirmesini doğrulayabilir, ancak eğitim rastgeleliğinin etkisini göstermez. Beş seed çalışması bu ikinci soruya yanıt arar. Bunun için model her koşuda yeniden başlatılır, farklı seed ile eğitilir ve önceden belirlenen doğrulama kaybı ölçütüne göre saklanır. Sonuçlar daha sonra aynı test kümesinde değerlendirilir. Bu prosedürün açık biçimde belgelenmesi, sonucun neyi ölçtüğünü doğru tanımlar.

Sonuçların analizinde ana deneyde kaydedilmiş değerlendirme tabloları ve beş-seed arşivindeki koşu bazlı CSV dosyaları temel alınmıştır. Grafiklerin bir bölümü bu tablolar üzerinden yeniden oluşturulmuştur. Yeni grafik çizimi yeni bir model eğitimi veya yeni bir test sonucu anlamına gelmez. Bu ayrım sayısal kayıtların korunması ve raporlanma aşamasının dürüst biçimde belgelenmesi açısından önemlidir.

Veri kümesi bölümü	Örnek sayısı
Eğitim	1257
Doğrulama	270
Test	270

Deneyin izlenebilirliği için eğitim, doğrulama ve test indeksleri ayrı bir dosyada saklanmıştır. Böylece farklı model aileleri arasında aynı örnekler üzerinden karşılaştırma yapılabilir. Sinir ağı eğitiminde en iyi epoch doğrulama kaybına göre seçildiğinden test kümesinin erken durdurma kararına katılması önlenir. Bununla birlikte test sonuçları görüldükten sonra başlatılan ek seed deneyleri yeni ve bağımsız bir test doğrulaması olarak yorumlanmamıştır. Bu deneylerin amacı sabit veri bölünmesi koşulunda eğitim rastgeleliğine duyarlılığı betimlemektir. Test kümesindeki örnekler aynı kaldığı için seed çalışmaları arasında hesaplanan ortalama, bağımsız beş ayrı veri toplama deneyinin yerini tutmaz.

4. Bulgular

Deneylerin temel sonuçları arşivde bulunan table_6_final_performance.csv dosyasından alınmıştır. Doğrulama puanıyla seçilen CNN-C modelinin doğrulama doğruluğu %99,259, test doğruluğu %98,148 ve test Macro F1 değeri %98,124 olarak kaydedilmiştir. Aynı test kümesinde SVM-RBF modeli %98,889 doğruluk ve %98,885 Macro F1 elde etmiştir. Bu sonuçlar model seçimi ile test değerlendirmesinin farklı ölçütler olabileceğini somutlaştırır.

Eşleştirilmiş CNN ve SVM tahminlerinde yalnızca altı gözlem üzerinde iki modelin doğruluk durumu farklıdır: dört örnekte CNN yanlış SVM doğru, iki örnekte CNN doğru SVM yanlıştır. McNemar exact p değeri 0,6875 olup testte gözlenen farkın güçlü bir üstünlük kanıtı olmadığını göstermektedir. Bootstrap ile oluşturulan doğruluk farkı güven aralığı sıfırı kapsamaktadır.

Kararlılık çalışmasında 101, 202, 303, 404 ve 505 rastgele başlangıçları kullanılmıştır. En düşük test başarısı 101 numaralı koşuda %98,889; en yüksek başarı 202 numaralı koşuda %99,630 olarak gözlenmiştir. Ortalama başarı %99,259 ve standart sapma 0,262 yüzde puan düzeyindedir. Tek bir koşunun en yüksek sonucunu nihai başarı olarak seçmek yerine tüm koşuları birlikte raporlamak daha doğru bir yaklaşımdır.

Beş koşunun en iyi epoch değerleri sırasıyla 34, 37, 31, 23 ve 50 olarak kaydedilmiştir. Doğrulama doğruluğu ortalaması yaklaşık %98,963, Macro F1 ortalaması %98,960 düzeyindedir. Test doğruluğunun bu ortalamanın üzerinde olması beklenmedik olmak zorunda değildir; sınırlı büyüklükte farklı alt kümelerin örnekleme değişkenliği söz konusudur.

Önceki beş-seed çalışmasının ortalama test doğruluğu %99,111 ve standart sapması yaklaşık 0,331 yüzde puandır. Son deneyde test ortalaması daha yüksek olsa da son çalışmanın doğrulama doğruluğu

ortalaması önceki çalışmanınkinden düşüktür. Bu nedenle son deneyi koşulsuz üstün olarak ilan etmek yanlış olur; çalışmanın amacı sabit ayrım altında sonuçların ne derece değiştiğini göstermektir.

Ana deneyde Logistic Regression modelinin test doğruluğu %98,519, Random Forest modelinin test doğruluğu yaklaşık %97,407 olarak kaydedilmiştir. Bu değerler raporun model karşılaştırma tablosunda tüm diğer algoritmalarla birlikte sunulmaktadır. Doğrulama ve test skorları arasında bazı algoritmalarda farklı yönlerde değişim bulunması, tek bir ayrımdaki performans tahmininin mutlak bir sıralama oluşturmadığını gösterir. Özellikle az sayıda test gözlemi olan veri kümelerinde sonuçların nedenlerini model özellikleriyle birlikte yorumlamak gerekir.

CNN-C modelinin eğitim doğruluğu ana deneyde %100 olarak kaydedilmiştir. Aynı koşulda doğrulama doğruluğu %99,259 seviyesindedir. Eğitim-doğrulama farkının yaklaşık 0,741 yüzde puan olması dikkat çekici bir sorun görünümünde değildir. Ancak bu sayı tek başına öğrenme davranışını göstermez; kayıp fonksiyonunun eğrisi ve hata yapılan örneklerin dağılımı da gerekir. Bu nedenle raporda eğitim ve doğrulama kaybına ilişkin ek grafiğe yer verilmiştir.

Beş-seed sonuçlarında toplam yanlış tahmin sayıları sırasıyla 3, 1, 2, 2 ve 2 olarak raporlanmıştır. Bu sayıların küçük olması yüzdelik doğrulukların birbirine çok yakın olmasını açıklar. Ayrıca her koşunun aynı 270 test gözlemini kullandığı unutulmamalıdır. Koşuların sonuçları arasındaki korelasyon nedeniyle beş doğruluğu beş bağımsız test veri kümesi gibi kullanarak genelleme güven aralığı hesaplamak uygun değildir.

Doğrulama kaybının en düşük olduğu epoch değerleri 23 ile 50 arasında değişmiştir. Bu sonuç, sabit bir durdurma noktasının tüm koşular için eşit derecede uygun olmayabileceğini gösterir. Önceden tanımlanan erken durdurma ve checkpoint düzeninin kullanılması, her koşuya aynı model seçimi ilkesinin uygulanmasını sağlamıştır. Bununla birlikte eğitim süresini etkileyen donanım koşulları ve paket sürümleri karşılaştırmanın doğrudan bir parçası değildir.

Başarı karşılaştırmasında yüzdelerin yanında doğru ve yanlış tahmin sayılarının da verilmesi, özellikle küçük test kümelerinde yorum kolaylığı sağlar. Örneğin CNN-C'nin yüzde 98,148 başarısı 270 örneğin 265'ini doğru tahmin etmesine, SVM'nin yüzde 98,889 başarısı ise 267 örneği doğru tahmin etmesine karşılık gelir. Yaklaşık bir yüzde puanlık fark gibi görünen miktar gerçekte yalnızca iki örnektir. Dolayısıyla görsel grafiklerdeki sütun farklarını örnek sayısı bağlamından koparmamak gerekir. Bu açıklama istatistiksel karşılaştırmanın neden sonuç bölümüne eklendiğini de gösterir.

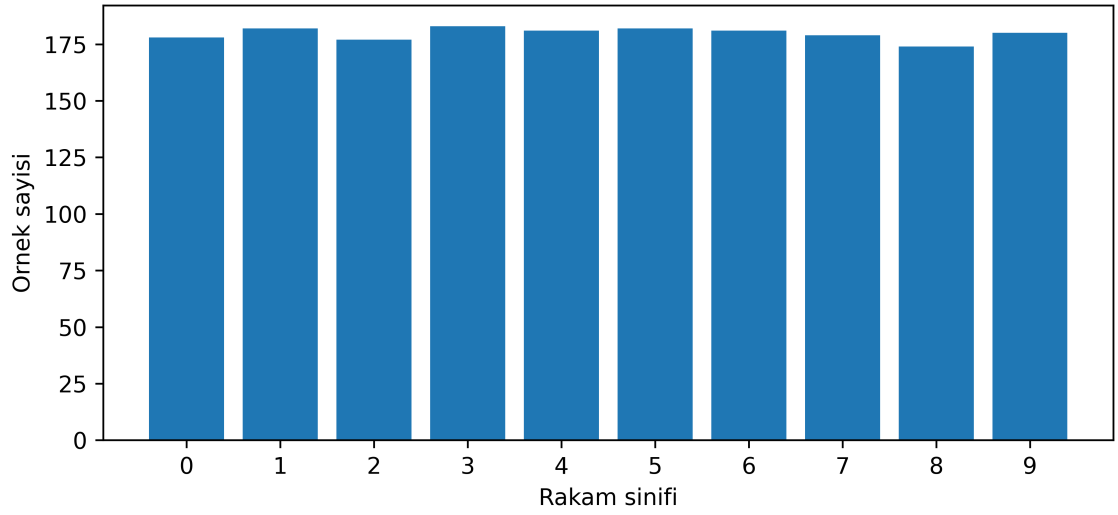
Beş-seed çalışmasının doğrulama doğrulukları birbirinden bir miktar farklıdır. En yüksek doğrulama doğruluğu 202 koşusunda, en düşük değerler ise 404 ve 505 koşularında kaydedilmiştir. Test sonuçlarında da 202 koşusu tekil olarak daha yüksek görünmektedir. Fakat tekil sıralamanın araştırmanın nihai modeli olarak kullanılması önceden belirlenmiş seçim ölçütü yoksa yanlılığa yol açar. Bu nedenle tabloda ortalama, değişkenlik ve tüm seed değerleri birlikte tutulmuştur. Tek bir sonucu öne çıkararak diğerlerini çıkarmak önerilmemektedir.

Öğrenme eğrileri raporda bağımsız bir sonuç türü olarak değerlendirilmelidir. Doğrulama kaybının bir süre azalıp daha sonra artması, bazı koşularda eğitim sürecinin durdurulmasını gerektiren bir işarettir. En iyi epoch değerlerinin koşular arasında farklılaşması, her eğitim için son epoch'u seçmenin aynı kalite ölçütünü sağlamayabileceğini göstermektedir. Checkpoint mekanizması sayesinde kaybı en düşük olan aşamanın ağırlıkları kullanılır. Bunun sonucunda bildirilen test skorları son eğitim adımının değil, doğrulama temelli belirlenen durumun performansını yansıtır.

Tüm sonuçların raporlanmasında daha büyük değerin otomatik olarak bilimsel üstünlük anlamına gelmediği esas alınmıştır. Yüzde olarak ifade edilen skorlar test gözlem sayısıyla birlikte okunmalıdır. Bunun yanında doğrulama performansı ayrı gösterilerek hangi ölçütün model seçimi için kullanıldığı anlaşılır hâle getirilmiştir. Farklı zamanlarda üretilmiş deneyler tek bir eğitim süreciymiş gibi sunulmamış, karşılaştırmanın sınırları açık biçimde korunmuştur.

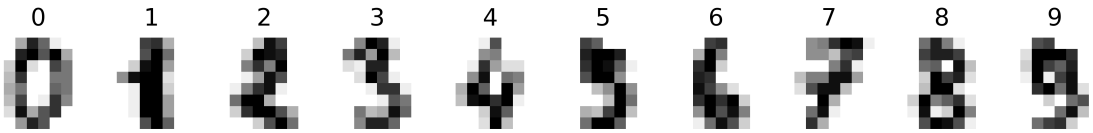
Model	Doğrulama (%)	Test (%)	Test makro F1 (%)
CNN-C	99.26	98.15	98.12
Logistic Regression	97.78	98.52	98.52
SVM (RBF)	97.41	98.89	98.88
Random Forest	96.67	97.41	97.38
KNN	96.30	98.15	98.15
Gradient Boosting	95.19	96.30	96.27

Sekil 1. Digits sinif dagilimi



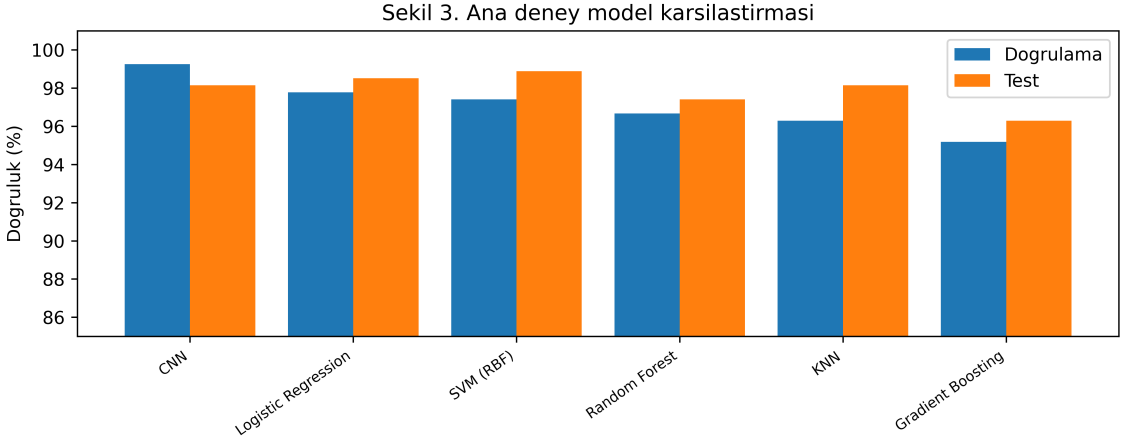
Şekil 1. Digits veri kümesinde rakam sınıflarının dağılımı

Sekil 2. Veri kumesinden ornek goruntuler

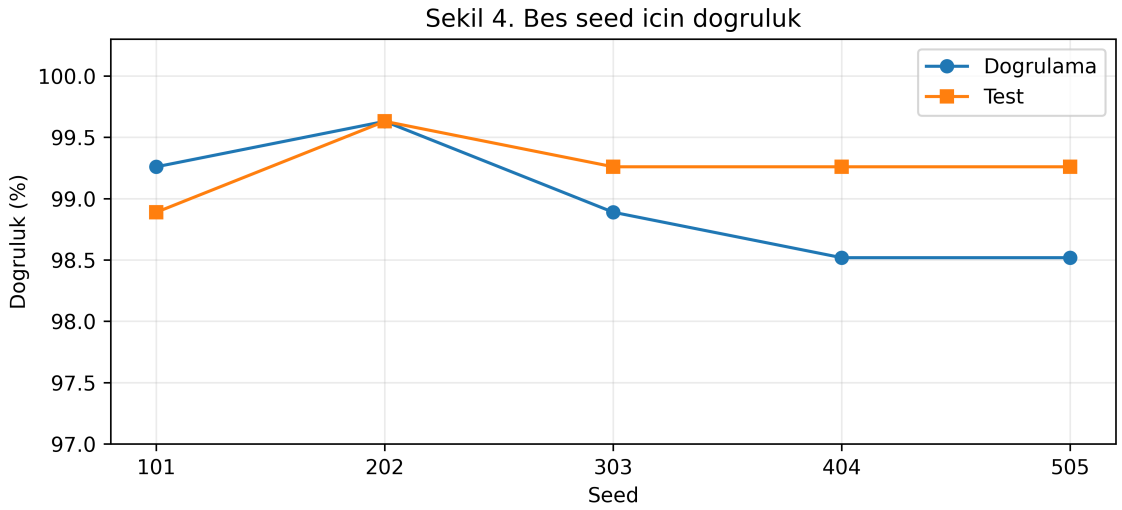


Şekil 2. Her rakam sınıfından örnek görüntüler

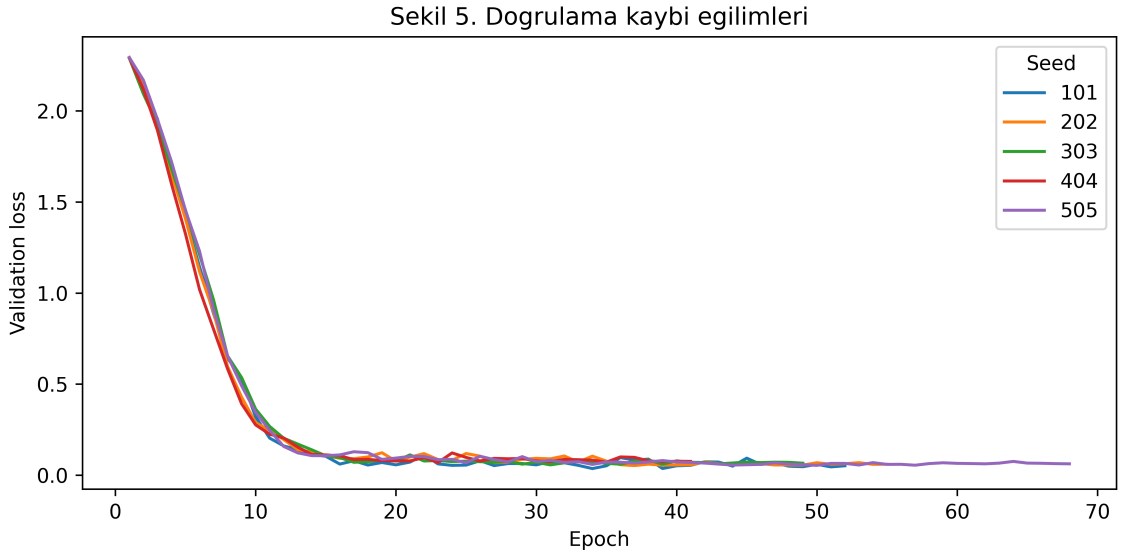
Sekil 3. Ana deney model karsilastirmasi



Şekil 3. Modellerin doğrulama ve test performansları



Şekil 4. CNN modelinin beş başlangıç tohumu için test doğrulukları



Şekil 5. CNN modelinin doğrulama kaybı eğrisi

Başlangıç tohumu	En iyi epoch	Test (%)	Makro F1 (%)
101	34	98.889	98.894
202	37	99.630	99.630
303	31	99.259	99.252
404	23	99.259	99.244
505	50	99.259	99.236

Tabloda verilen test yüzdeleri, sınırlı sayıdaki örneğe karşılık gelen tam sayı doğru tahminlerinden elde edilmektedir. Bu nedenle küçük ondalık yüzdelik farklar geniş ve genellenebilir bir üstünlük olarak yorumlanmamalıdır. Son beş-seed deneyinde bütün koşuların sonuçlarının birlikte sunulması, yalnızca en yüksek skoru veren koşunun raporlanmasından daha tutarlı bir özet sağlar. Seed sonuçları arasındaki değişkenlik, modelin başlangıç koşullarına göre verdiği yanıtı gösterir; farklı veri kümeleri veya farklı test ortamları üzerinde genelleme garantisi oluşturmaz. Önceden tanımlanan model seçimi ilkesi ile sonradan yapılan hata analizi bu nedenle ayrı değerlendirilmiştir.

5. Tartışma

Ana deneyde doğrulama doğruluğu en yüksek model CNN-C iken test doğruluğunda SVM'nin küçük bir üstünlüğü vardır. Bu durum çelişki değildir; doğrulama ve test verileri sınırlı sayıda farklı örnek içerir. Testte SVM 267, CNN 265 örneği doğru sınıflandırmıştır. İki tahminlik fark tek başına model kalitesindeki kalıcı bir ayrımı göstermeyebilir. Arşivdeki eşleştirilmiş McNemar testinin p değeri 0,6875 olduğundan üstünlük için yeterli istatistiksel kanıt bulunmamaktadır.

Ek beş-seed deneyinde test doğruluğunun ortalaması %99,259, standart sapması yaklaşık 0,262 yüzde puandır. Eğitimlerin en düşük ve en yüksek test doğruluğu sırasıyla %98,889 ve %99,630 olmuştur. Beş sonuç birbirine yakın olduğundan sabit veri ayrımında rastgele başlangıç kaynaklı değişimin sınırlı olduğu görülür. Ancak farklı veri ayrımları yapılmadığı için bu değer güven aralığı veya bağımsız veri kümesi genelleme tahmini olarak okunmamalıdır.

Overfitting değerlendirmesinde yalnızca test doğruluğuna bakmak yeterli değildir. Ana deneyde CNN'nin eğitim doğruluğu %100 ve doğrulama doğruluğu yaklaşık %99,259 olduğundan gözlenen fark yaklaşık 0,741 yüzde puandır. Bu küçük fark olumlu görünse de eğitim ve doğrulama loss eğrileri birlikte incelenmelidir. Kararlılık deneyinde doğrulama kaybının daha sonra artabilmesi nedeniyle erken durdurma ve doğrulama kaybı ölçütüne göre ağırlıkların geri yüklenmesi kritik rol oynar.

Bu araştırma küçük, standartlaştırılmış ve düşük çözünürlüklü bir veri kümesine dayanır. Gerçek dünya el yazısı fotoğraflarında ışık, arka plan, farklı görüntü çözünürlükleri ve dağılım kayması görülebilir. Dolayısıyla bildirilen yüksek doğruluk, gerçek hayattaki tüm el yazısı uygulamalarına doğrudan genellenemez. Ayrıca beş-seed deneyinden önce test sonuçlarının görülmüş olması, en iyi görünen yeni koşuyu bilimsel yöntem üstünlüğü olarak seçmeyi sakıncalı kılar.

Gözlenen SVM–CNN farkının yorumlanmasında iki önemli nokta öne çıkar. Birincisi, farkın yalnızca iki test örneğine karşılık gelmesidir. İkincisi ise her iki modelin farklı gözlemlerde hata yapabilmesidir. Bu nedenle modellerin toplam doğru sayıları kadar, hangi örneklerde ayrıştıkları da önem taşır. Eşleştirilmiş test bu sorunun daha uygun istatistiksel ifadesidir; elde edilen p değeri kesin bir üstünlük iddiasını desteklemez.

CNN'nin beş koşuda yüksek doğruluk göstermesi, görüntü uzayındaki örüntüleri öğrenen mimarinin sabit veri ayrımında tutarlı davranabildiğine işaret eder. Bununla birlikte bunun sadece model mimarisinden mi, belirli veri kümesinin görece kolay olmasından mı yoksa veri ayrımına özgü özelliklerden mi kaynaklandığı bu deneyle ayrı ayrı belirlenemez. Farklı kişilerden toplanmış bağımsız dış veri kümeleri bu soruyu araştırmak için daha güçlü olacaktır.

Önceki ve son kararlılık çalışmaları arasındaki yaklaşık 0,148 yüzde puanlık test ortalama farkı ilk bakışta son deney lehine görünmektedir. Ancak doğrulama ortalamasının yönü ters olduğundan bu fark genel bir model ilerlemesi olarak sunulmamalıdır. Ayrıca her iki deney daha önceki sonuçlarla aynı bağlamda değerlendirildiği için çoklu deneme yanlılığı söz konusudur. Sonuçların tümünü saklamak ve testin model seçimi amacıyla kullanılmadığını açıklamak daha şeffaf bir araştırma pratiğidir.

Bir başka sınırlılık, veri setinin görüntülerinin yalnızca 8 × 8 olmasıdır. Düşük çözünürlük hem hesaplama açısından avantaj sağlar hem de daha karmaşık el yazısı örneklerindeki ince ayrıntıları ortadan kaldırabilir. Veri kümesinin standartlaştırılmış yapısı, mobil kamera üzerinden elde edilen düzensiz ve gürültülü görüntülerin karşılığı değildir. Üretim ortamı tasarlayan bir uygulama geliştiricisinin gerçek saha verisi toplamadan bu sonucu doğrudan ürün başarısı olarak değerlendirmemesi gerekir.

Son olarak bu karşılaştırmanın pedagojik değeri yalnızca hangi modelin yüzde olarak öne çıktığında değildir. Veri hazırlama, algoritmaların karşılaştırılması, doğrulamayla seçme, test sonucu raporlama, aşırı öğrenmeyi analiz etme ve tekrarlanabilir deney kaydı birlikte ele alınmıştır. Bu bütünlük, tek bir

yüksek başarı sayısından daha güçlü bir akademik gerekçe sağlar ve sonraki çalışma tasarımlarında hangi belirsizlik kaynaklarının giderilmesi gerektiğini gösterir.

Bir araştırmanın sınırlarını açıkça belirtmek, elde edilen yüksek başarıyı değersizleştirmez; tam tersine sonucun hangi koşullarda geçerli olduğunu tanımlar. Buradaki sonuçlar Digits veri kümesinin 8 × 8 özellik gösterimi, kayıtlı eğitim-doğrulama-test ayrımı ve belirtilen kütüphane ortamı altında geçerlidir. Daha farklı cihazlardan toplanan gerçek el yazısı örnekleri, farklı çözünürlükler ve kullanıcı profilleri için aynı başarı oranlarının korunacağı çıkarımı yapılamaz. Bu nedenle modelin saha kullanımına uygunluğunu değerlendirmek ek deney tasarımı gerektirmektedir.

Sonuçların tekrarlanabilirliği yalnızca kodun açık olmasına değil, deney tanımlarının ve veri kaynaklarının yeterli açıklıkta olmasına bağlıdır. Bir okuyucunun hangi modelin hangi dosyadan geldiğini, hangi veri indeksleriyle eğitildiğini ve raporlanan metriklerin hangi tahminlerden hesaplandığını görebilmesi gerekir. Bu teslim kapsamında ana deneyin özgün arşivi, son kararlılık deneyinin özgün arşivi ve karşılaştırma tablosu ayrı tutulmuştur. Böylece farklı zamanlarda çalıştırılmış deneylerin sonuçları birbirine karıştırılmadan değerlendirilebilir.

Model başarısının farklı yönlerini ölçen metrikler bazen birbirine yakın sonuçlar verir. Accuracy ve Macro F1'in bu projede yakın olması tüm hataların önemsiz olduğu anlamına gelmez. Örneğin bazı rakamlar benzer biçimler taşıdığından hatalar küçük bir alt grupta yoğunlaşabilir. Böyle bir durumda karmaşıklık matrisleri ve sınıf bazında ölçümler, ortalama değerlerin saklayabildiği zayıflıkları ortaya çıkarır. Geliştirme kararları daha sonra alınacaksa bu ayrıntılar önemlidir; mevcut çalışmada ise test sonuçlarını izleyerek yeni bir model seçmekten özellikle kaçınılmıştır.

Sonuçta yüksek doğruluk, düşük kararlılık değişkenliği ve küçük genelleme farkı olumlu bulgulardır; fakat her biri yalnızca kendi ölçtüğü soruya cevap verir. Düşük seed değişkenliği farklı veri bölünmelerindeki başarıyı garanti etmez. Küçük eğitim-doğrulama farkı bütün overfitting türlerinin bulunmadığını kanıtlamaz. Yüksek test doğruluğu da modeller arasındaki küçük farkların istatistiksel açıdan anlamlı olduğu anlamına gelmez. Bu ayrımların korunması, akademik rapordaki temel değerlendirme mantığını oluşturur.

6. Sonuç

Aynı eğitim, doğrulama ve test bölünmesi altında birden fazla algoritma ailesi karşılaştırılmış, sinir ağının doğrulama aşamasındaki yüksek başarısına karşılık testte SVM için küçük bir avantaj gözlenmiştir. Eşleştirilmiş karşılaştırma bu fark için istatistiksel üstünlük kanıtı sunmamıştır. Sonuçlar, model seçiminin test kümesinden ayrı yapılmasının önemini ortaya koymaktadır.

CNN-C modelinin beş farklı başlangıçla yeniden eğitimi, sabit veri bölünmesi koşullarında ortalama test doğruluğunun %99,259 olduğunu göstermiştir. Bununla birlikte çalışmalar gerçek dünyadaki farklı yazım biçimlerine, cihazlara ya da görüntü koşullarına ilişkin dış doğrulama içermemektedir. Gelecekte grup bazlı yeni veri toplama ve önceden tanımlanmış bir dış test protokolü uygun olacaktır.

Bu çalışma, küçük ölçekli görüntü sınıflandırma problemlerinin dikkatli bir deney protokolüyle incelenebileceğini ortaya koymuştur. Başarılı modellerin test doğrulukları yüksek olsa da küçük örneklem ve ortak veri bölünmesi, sonuçların yorumlanmasında ihtiyat gerektirir. Makine öğrenmesi yöntemleri ile derin öğrenme yaklaşımının birlikte raporlanması, çok sayıda algoritma ailesi arasında adil bir karşılaştırmaya olanak sağlamıştır.

Gelecek bir çalışmada test kümesinin deney tasarımı tamamlanana kadar tamamen kapalı tutulması, sınıflandırıcıların daha geniş ve bağımsız veri üzerinde yeniden değerlendirilmesi ve farklı veri bölünmelerinin eklenmesi önerilir. Böyle bir protokol, rastgele başlangıç etkisi ile örnekleme etkisini

ayırmaya ve değişen görüntü koşullarında modellerin gerçekten ne kadar kararlı olduğunu araştırmaya yardımcı olacaktır.

Sonuçların en güçlü yanı, farklı öğrenme yaklaşımlarının aynı değerlendirme koşullarında ele alınması ve ek CNN deneyinin tüm koşularla birlikte kaydedilmesidir. Böylece gözlenen performans farkları model ailesi, rastgele başlangıç ve değerlendirme ayrımı bağlamında daha doğru yorumlanabilmektedir. Araştırmanın temel sonucu bir algoritmanın kesin üstünlüğü değil, model seçimi ve güvenilir raporlamanın birlikte yürütülmesinin gerekli olduğudur.

Deneyin daha ileri bir sürümü için önce yeni değerlendirme planı kayıt altına alınmalı, ardından modeller geliştirilip son aşamada daha önce incelenmemiş veri üzerinde değerlendirilmelidir. Böyle bir yaklaşım test kümesine aşırı uyum riskini azaltır. Çalışmanın mevcut hali öğrenme sürecinde kurulan yöntemsel disiplini ortaya koyarken, üretime dönük genelleme konusunda temkinli kalmaktadır.

Sonuçların değerlendirilmesinde hem test başarısının hem de uygulanan seçim protokolünün önemi ortaya çıkmaktadır. Modelin başarısı hakkındaki en güçlü yorum, tekil en yüksek skor yerine karşılaştırmanın kapsamı ve belirsizlikleri açıkça belirtilerek yapılabilir. Sabit test kümesindeki başarı, dış veri üzerinde bağımsız doğrulama yapılmadan gerçek kullanım başarısına eşitlenmemelidir.

Kaynakça

[1] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278–2324.

[2] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

[3] Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20, 273–297.

[4] Breiman, L. (2001). Random forests. Machine Learning, 45, 5–32.

[5] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. Annals of Statistics, 29(5), 1189–1232.

[6] Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. IEEE Transactions on Information Theory, 13(1), 21–27.

[7] Cox, D. R. (1958). The regression analysis of binary sequences. Journal of the Royal Statistical Society: Series B, 20(2), 215–242.

[8] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. Nature, 323, 533–536.

[9] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems, 25.

[10] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. Journal of Machine Learning Research, 15, 1929–1958.

[11] Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. Proceedings of ICML, 448–456.

[12] Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. Proceedings of ICLR.

[13] Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. Proceedings of IJCAI, 1137–1143.

[14] Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. Neural Computation, 10(7), 1895–1923.

[15] McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. Psychometrika, 12, 153–157.

[16] Efron, B., & Tibshirani, R. J. (1993). An introduction to the bootstrap. Chapman & Hall/CRC.

[17] Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. Information Processing & Management, 45(4), 427–437.

[18] Fawcett, T. (2006). An introduction to ROC analysis. Pattern Recognition Letters, 27(8), 861–874.

[19] Varoquaux, G. (2018). Cross-validation failure: Small sample sizes lead to large error bars. NeuroImage, 180, 68–77.

[20] Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. Journal of Machine Learning Research, 11, 2079–2107.

[21] Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 32.

[22] Abadi, M., et al. (2016). TensorFlow: A system for large-scale machine learning. Proceedings of OSDI, 265–283.

Yapay zekâ kullanımı beyanı

Bu çalışmada yapay zekâ araçlarından kodun gözden geçirilmesi, sonuçların düzenlenmesi, dil ve rapor taslağı oluşturulması amacıyla yararlanılmıştır. Sayısal sonuçlar çalıştırılan deney arşivlerinden alınmıştır. Nihai metin, kaynaklar ve kodun işleyişi teslim öncesinde öğrenci tarafından kontrol edilmeli ve kullanılan araçlar ile kullanım kapsamı gerektiğinde ayrıntılandırılmalıdır.

Kod ve veri bağlantıları

Veri kümesi: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html

GitHub kod deposu: https://github.com/ReyhanOnbasi/El-Yazisi-Rakam-Siniflandirma