Rapor 2 — Akademik Makale: Digits Veri Kümesinde Sınıflandırıcıların Karşılaştırılması

Reyhan Onbaşı | Öğrenci No: 202612696008 | YSA F26

Özet

El yazısı rakam görüntülerinin sınıflandırılması, klasik makine öğrenmesi ile derin öğrenme yaklaşımlarının ortak bir protokol altında karşılaştırılabildiği bir problemdir. Bu çalışmada scikit-learn Digits veri kümesindeki 1.797 adet 8 × 8 görüntü sınıf oranları korunarak 1.257 eğitim, 270 doğrulama ve 270 test örneğine ayrılmıştır. Beş farklı klasik algoritma ailesi ile iki çok katmanlı algılayıcı ve bir evrişimsel sinir ağı karşılaştırılmıştır.

Hiperparametreler yalnızca eğitim ve doğrulama verileri kullanılarak belirlenmiştir. CNN-C doğrulama makro F1 değeri 0,99266 ile seçilmiş; bağımsız testte %98,15 doğruluk ve 0,98124 makro F1 elde etmiştir. RBF-SVM'nin test doğruluğu %98,89 olmasına karşın kesin McNemar testi p=0,6875 sonucu vermiştir. Sabit veri ayrımında CNN-C'nin beş farklı başlangıçla tekrarında ortalama test doğruluğu %98,74, örnek standart sapması yaklaşık 1,13 yüzde puandır. Üç mimarinin üçer tekrarı yalnızca doğrulama verisiyle ayrıca incelenmiştir.

Bulgular, model seçiminde test verisinin kullanılmaması gerektiğini ve küçük test kümelerinde birkaç gözlemlik farkın yöntem üstünlüğü sayılmaması gerektiğini vurgular. Ek tohum deneyleri bağımsız dış doğrulama olarak değil, eğitim rastgeleliğine ilişkin keşifsel analiz olarak yorumlanmıştır.

1. Introduction

El yazısı rakamların sınıflandırılması, düşük çözünürlüklü görüntülerde örüntü tanımanın temel bir örneğidir. Aynı rakam farklı kişiler tarafından farklı kalınlık, açı ve eğrilikte yazılabilir. Bu çeşitlilik nedeniyle sayısal piksel benzerliğine dayanan bir yöntem her zaman yeterli olmayabilir. Bu çalışmada geleneksel makine öğrenmesi sınıflandırıcıları ile evrişimsel sinir ağı yaklaşımı aynı veri bölünmesi üzerinde karşılaştırılmıştır. Temel amaç yalnızca yüksek bir başarı değeri bildirmek değil, doğrulama temelli model seçimi ile bağımsız test değerlendirmesini birbirinden ayırmaktır.

Çalışmanın veri kaynağı scikit-learn Digits veri kümesidir. Toplam 1.797 gözlem, 0 ile 9 arasındaki on sınıfa aittir ve her örnek 8 × 8 pikselden oluşur. Piksel değerleri 0–16 aralığındadır. Geleneksel algoritmalar için görüntüler 64 özellikli vektörlere dönüştürülürken CNN için iki boyutlu görüntü yapısı korunmuştur. Bu farklı gösterim biçimleri, algoritmaların veri yapısına uygun öğrenme özelliklerini değerlendirmek için kullanılmıştır.

Deney arşivindeki ayrım 1.257 eğitim, 270 doğrulama ve 270 test örneğinden oluşur. Test kümesinin model seçimine katılmaması, raporlanan başarının iyimserlik yanlılığını azaltmak için önemlidir. Kayıtlı çıktıların incelenmesi sonucunda birden fazla klasik sınıflandırıcı ve yapay sinir ağı ailesi karşılaştırılmış; sonradan ayrıca sabit veri ayrımı altında beş farklı rastgele başlangıçla CNN kararlılık deneyi yürütülmüştür. Bu ek deney farklı test kümelerini değil, aynı ayrım koşulunda eğitim rastgeleliğinin etkisini inceler.

Küçük görüntü veri kümelerindeki değerlendirmelerin özel bir güçlüğü vardır. Test kümesindeki tek bir hatalı tahmin, yüzdelik başarı değerini anlamlı görünen miktarda değiştirebilir. Bu nedenle yüzdelik başarıların basamak sayısı, belirsizliğin olduğundan daha düşük görünmesine neden olmamalıdır. Buradaki test kümesinde 270 gözlem vardır; tek bir gözlemin doğruluk üzerindeki etkisi yaklaşık 0,370 yüzde puandır. İki model arasındaki birkaç tahminlik farkı yöntem üstünlüğü olarak yorumlamak için eşleştirilmiş karşılaştırmanın sonuçları ayrıca değerlendirilmelidir.

Modelin eğitime uyum sağlaması ile daha önce görmediği verilerdeki başarısı birbirinden ayrılmalıdır. Eğitim verisi üzerinde elde edilen çok yüksek doğruluk, temsil kapasitesi yüksek bir modelin örnekleri ezberlemiş olabileceği ihtimalini dışlamaz. Doğrulama kümesi eğitim sürecindeki kararların verilmesini, test kümesi ise bu kararlar sabitlendikten sonra nihai performansın değerlendirilmesini sağlar. Bu iki rolün karıştırılması, ölçülen başarının gerçeği olduğundan yüksek göstermesine neden olabilir.

Bu araştırma özellikle yorumlanabilir deney tasarımını ön plana çıkarır. Karşılaştırılan yöntemlerin farklı algoritma ailelerinden seçilmesi, tek bir mimariyi farklı sayıda katmanla tekrar tekrar eğitmekten daha geniş bir karşılaştırma üretir. Aynı zamanda tek bir modelin birden fazla rastgele başlangıçla çalıştırılması, farklı bir araştırma sorusuna cevap verir: sabit veri ayrımı ve mimari altında eğitimin başlangıç koşullarına duyarlılığı. Bu iki sorunun aynı tabloda karıştırılmaması gerekir.

Çalışmanın ikinci katkısı, model karşılaştırmasını yalnızca en yüksek sonucu bulma çabasına indirgememesidir. Ana deney doğrulama temelli seçimin sonuçlarını gösterirken ek CNN çalışması beş farklı başlangıcın ortalamasını ve değişkenliğini sunar. Bu düzen, modelin davranışındaki küçük değişimlerin ne kadar önemli olduğuna ilişkin daha ihtiyatlı bir yorum sağlar. Bulguların kendi deney koşullarının sınırları içinde değerlendirilmesi, sonucun gerçek dünya uygulamaları için ne anlama geldiğini daha açık hâle getirir.

Bu yönüyle çalışmanın araştırma sorusu iki katmanlıdır: farklı algoritmaların sabit koşullardaki göreli performansı ve seçilmiş CNN mimarisinin eğitim rastgeleliğine duyarlılığı. Raporun yöntem ve sonuç bölümleri bu iki soruyu birbirinden ayrı tanımlar. Karşılaştırmanın amacı üretim ortamında kesin performans iddiasında bulunmak değil, deney protokolünün gerektirdiği kanıtları adım adım sunmaktır.

Bu çalışmanın temel araştırma sorusu, aynı veri bölünmesiyle değerlendirilen farklı öğrenme yaklaşımlarının başarı farklarının nasıl yorumlanacağıdır. Özellikle test kümesindeki birkaç örneğin değişmesinin doğruluk yüzdesini belirgin biçimde etkileyebileceği dikkate alınmıştır. Bu nedenle yalnızca en yüksek puanın raporlanması yerine doğrulama ile test sonuçları ayrı tutulmuş, modellerin ortak ve farklı hataları incelenmiş ve CNN için farklı başlangıç koşullarında elde edilen sonuçlar birlikte değerlendirilmiştir.

2. Literature Review

LeCun ve çalışma arkadaşlarının 1998 tarihli doküman tanıma araştırması, piksellerin yerel komşuluk yapısını kullanan evrişimsel ağların görüntü sınıflandırma açısından önemini göstermiştir. Bu yaklaşım, düzleştirilmiş vektör üzerinde çalışan klasik sınıflandırıcılardan farklı bir temsil öğrenme mekanizmasına dayanır. Buradaki CNN-C deneyinin kavramsal temeli de yerel filtreleme, özellik hiyerarşisi ve sınıflandırma katmanlarının birlikte öğrenilmesidir. [1]

Cortes ve Vapnik tarafından sunulan destek vektör makineleri sınıflar arasındaki ayrımı marjini artırarak sağlamayı hedefler. RBF çekirdeği doğrusal olmayan ilişkileri yakalamayı kolaylaştırır. Bu veri kümesinde SVM yönteminin güçlü olması, boyutu görece küçük ve iyi düzenlenmiş piksellerden oluşturulan örneklerde çekirdek tabanlı karar sınırlarının başarılı olabileceği beklentisiyle uyumludur. [3]

Breiman'ın Random Forest yaklaşımı çok sayıda karar ağacından elde edilen tahminleri birleştirir. Friedman'ın Gradient Boosting yöntemi ise ardışık zayıf öğrenicilerin hatalarını azaltmayı hedefleyen topluluk yaklaşımıdır. İki yöntemin tek bir ağaçtan farklı olarak tahmin varyansını ve yanlılığı yönetme biçimleri, görüntü verisi üzerindeki farklı sonuçları yorumlamak için önemlidir. [4, 5]

Cover ve Hart tarafından incelenen en yakın komşu sınıflandırması eğitim verisine olan uzaklığa dayalı basit ama etkili bir temel yöntem sağlar. Lojistik regresyon ise karar fonksiyonunun girdilerle ilişkisini

doğrusal parametrelerle ifade eder. Bu çalışmada farklı algoritma ailelerini bir arada değerlendirmek, başarıyı yalnızca sinir ağı mimarisine bağlamadan yorumlayabilmek için önemlidir. [6, 7]

Rumelhart ve arkadaşlarının geri yayılım yaklaşımı öğrenilebilir ağırlıkların kayıp gradyanıyla güncellenmesini açıklamıştır. Daha sonra büyük ölçekli görüntü sınıflandırması için derin evrişimsel ağların kullanımı Krizhevsky ve arkadaşlarının ImageNet çalışmasıyla önemli bir görünürlük kazanmıştır. Ancak büyük veri üzerinde kurulmuş başarı beklentilerini doğrudan 1.797 örnekli Digits kümesine aktarmak mümkün değildir. [8, 9]

Srivastava ve arkadaşlarının dropout yöntemi eğitim sırasında bazı bağlantıları geçici olarak etkin dışı bırakıp eş-uyum riskini azaltır. Ioffe ve Szegedy'nin batch normalization yöntemi eğitim davranışını düzenler; Kingma ve Ba tarafından geliştirilen Adam optimizasyonu gradyan temelli güncellemeleri adaptif hâle getirir. Bu yöntemlerin bir arada bulunması, doğrulama eğrilerinin yorumlanmasını gereksiz kılmaz. [10, 11, 12]

Kohavi'nin çapraz doğrulama ve bootstrap karşılaştırmaları model değerlendirme yönteminin önemini vurgular. Cawley ve Talbot, model seçiminin kendisinin de aşırı uyum yaratabileceğine dikkat çeker. Varoquaux ise küçük örneklem koşullarındaki geniş belirsizlik aralıklarının altını çizmiştir. Böylece bu projedeki yüksek yüzde değerleri, özellikle çok sayıda tekrar deneme yapıldığında dikkatle değerlendirilmelidir. [13, 19, 20]

Dietterich'in sınıflandırıcı karşılaştırmaları üzerine değerlendirmesi ve McNemar'ın eşleştirilmiş oranlar testi, aynı test gözlemlerinde oluşan farklılıkların yalnızca çıplak doğruluk puanıyla sınırlı kalmaması gerektiğini gösterir. Efron ve Tibshirani tarafından sistemleştirilen bootstrap yöntemleri ise karşılaştırmadaki belirsizliği örnekleme yoluyla ifade etmeye yardımcı olur. [14, 15, 16]

Sokolova ve Lapalme sınıflandırma metriklerinin farklı özelliklerini sistematik biçimde tartışmıştır. Fawcett, ROC eğrisinin model başarısını farklı karar eşiklerinde değerlendirme amacıyla kullanılabileceğini göstermiştir. Bu projede accuracy yanında Macro F1 ve ROC-AUC sunulması, ölçümün tek sayıya indirgenmemesi için tercih edilmiştir. [17, 18]

Pedregosa ve arkadaşlarının scikit-learn yazılımına ilişkin çalışması, çok sayıda algoritmanın ortak API ile karşılaştırılmasını mümkün kılan bir uygulama zemini sunar. TensorFlow yazılımının büyük ölçekli öğrenme altyapısı da derin modellerin eğitilmesinde kullanılan ekosisteme katkıda bulunmuştur. Kullanılan yazılım ve paket sürümlerini raporlamak, bir deneyin tekrar üretilebilmesine yardımcı olur. [2, 22] PyTorch [21] literatürde başka bir yaygın derin öğrenme altyapısıdır; bu deneyde PyTorch ile model eğitimi yapılmamıştır.

Sınıflandırma literatüründe sık karşılaşılan bir sorun, farklı veri kümeleri ve farklı test koşulları altında raporlanan doğrulukların doğrudan karşılaştırılmasıdır. Oysa aynı algoritma uygulamasının farklı ayrımlarda veya farklı ön işleme tercihleriyle farklı performans göstermesi mümkündür. Bu nedenle deneysel çalışmalarda veri bölünmesi, veri dönüşümleri, model seçimi ve kullanılan metrikler şeffaf biçimde belgelenmelidir. Eğitim boyunca test kümesinden gelen sinyallerin karar mekanizmasına karışmaması bu belgelemenin en önemli parçasıdır.

Evrişimsel ağların güçlü yönlerinden biri, komşu pikseller arasındaki yerel örüntüleri filtreler aracılığıyla temsil edebilmesidir. Bununla birlikte yalnızca sekiz piksel genişliğinde görüntülerde derinlik ve havuzlama tercihleri farklı sonuçlara yol açabilir. Küçük görüntüler için daha büyük ağın otomatik olarak daha başarılı olacağı söylenemez. Regularization, model kapasitesi, öğrenme hızı ve veri miktarı birlikte değerlendirilmelidir. Bu bakımdan CNN-C mimarisi için kaydedilmiş parametreler, sonraki çalışmaların karşılaştırılabilirliğini sağlar.

Performans ölçümleri konusu literatürde merkezi bir yer tutar. Accuracy dengeli kümelerde kolay yorumlanabilir, fakat tek başına hangi sınıfların daha zor olduğunu göstermeyebilir. Sınıf başına precision ve recall, belirli rakamların karıştırılmasını incelemek için yararlıdır. Macro F1'in her sınıfa

eşit ağırlık vermesi, performansı yalnızca örnek sayısı yüksek sınıfların belirlemesini engeller. Çok sınıflı ROC-AUC ise modelin olasılıksal ayrıştırma davranışına başka bir bakış sunar.

Çok sayıda deneme yapılan projelerde model seçiminin test verisine dolaylı uyum sağlama tehlikesi vardır. Bir araştırmacı test sonucunu inceledikten sonra tekrar tekrar yeni modeller dener ve sonunda en yüksek puanı raporlarsa, bu değer bağımsız değerlendirme özelliğini kısmen kaybetmiş olur. Cawley ve Talbot tarafından incelenen model seçim yanlılığı burada doğrudan önem taşır. Bu nedenle son deneylerin önceki test sonuçları görüldükten sonra yapıldığı açıkça belirtilmekte, nihai yorum ortalama ve sınırlar üzerinden kurulmaktadır.

3. Materials and Methods

Ön işleme aşamasında görüntülerin ölçüm aralığı ve algoritmaların beklediği girdi biçimi dikkate alınmıştır. CNN deneyinde piksel değerleri 16'ya bölünerek [0,1] aralığına ölçeklenmiş ve her görüntü (8,8,1) tensörüne dönüştürülmüştür. Bu dönüşüm veri kümesinin bilinen sabit piksel aralığına dayandığından öğrenilmiş bir test istatistiği içermez. Klasik yöntemlerde eğitim verisinden öğrenilmesi gereken dönüşümler varsa bunların yalnızca eğitim kümesi üzerinde fit edilmesi gerekir; her model için arşivdeki işlem hattı ayrıca kontrol edilmelidir.

Özgün deney kapsamında Logistic Regression, RBF çekirdekli SVM, Random Forest, KNN, Gradient Boosting ve sinir ağı modelleri değerlendirilmiştir. Bu algoritmalar farklı öğrenme varsayımlarını temsil eder: doğrusal karar sınırları, çekirdek yöntemleri, komşuluk benzerliği, ağaç toplulukları ve öğrenilen görüntü temsilleri. Yöntemlerin yalnızca hiperparametre sürümleri birbirinden bağımsız algoritma olarak sayılmamıştır.

CNN-C modeli 32 filtreli iki evrişim katmanı, batch normalization, havuzlama, dropout, 64 filtreli bir ek evrişim, global ortalama havuzlama ve yoğun katmanlar içerir. Dropout oranı 0,30, L2 katsayısı 0,0001, Adam öğrenme oranı 0,001 ve minibatch büyüklüğü 32 olarak kaydedilmiştir. Derin ağın nihai sınıflandırma katmanı 10 çıkışlı softmax yapısıdır. Kayıtlı mimarinin toplam parametre sayısı 33.002'dir.

Ana deneyde model seçimi doğrulama performansına dayandırılmıştır. Beş-seed ek deneyde her koşu için en düşük doğrulama kaybındaki ağırlıklar tutulmuş, erken durdurma yaklaşımı kullanılmıştır. Eğitim en fazla 250 epoch olarak planlanmasına rağmen en uygun kayıt noktası koşuya göre değişmiştir. Böylece tek bir rastgele başlangıca bağımlı performans bildirme sorunu azaltılmaya çalışılmıştır.

Doğruluk, tüm gözlemler içinde doğru tahminlerin payını gösterir. Macro F1 ise her sınıfın F1 skorunu eşit ağırlıkla ortalayarak sınıf bazlı performans dengesini daha iyi görünür kılar. ROC-AUC, tek eşik üzerinden verilen kararların ötesinde ayrıştırma başarısını özetler. Model karşılaştırmasında doğrulama ve test sonuçlarını ayrı göstermek gereklidir; test kümesinden öğrendikten sonra yeni denemeler tasarlamak bilimsel olarak ek seçim yanlılığı doğurabilir.

Tek Colab oturumunda, sabit rastgele bölünme (seed=42) için eğitim, doğrulama ve test indeksleri split_indices.npz dosyasında saklanmıştır. Üç kümenin kesişmediği, sayılarının 1.257/270/270 olduğu ve toplamda 1.797 ayrı indeksi kapsadığı doğrulanmıştır. Klasik modeller için StandardScaler gibi eğitimden öğrenilen ön işlemler çapraz doğrulama sırasında Pipeline içinde uygulanmış, CNN girdisi ise veri kümesinin bilinen 0–16 piksel aralığından [0,1] aralığına getirilmiştir.

Sınıflandırıcıları karşılaştırırken algoritmanın girdiye ilişkin varsayımları da dikkate alınmıştır. KNN örnekler arasındaki uzaklık ilişkisini, SVM dönüştürülmüş özellik uzayındaki marjini, ağaç toplulukları özelliklere dayalı bölme kurallarını ve CNN yerel uzamsal filtreleri kullanır. Bu farklılıklar, aynı veri bölünmesi üzerinde elde edilen sonuçların neden bire bir eşit olmayabileceğini açıklayan temel

mekanizmalardır. Bu çalışmada temel değerlendirme, algoritmaların teorik üstünlüğüne değil söz konusu veri kümesindeki gözlenen davranışına odaklanmıştır.

Ölçekleme, özellik seçimi veya parametre ayarı eğitim örneklerinden öğreniliyorsa bu işlem test verisi kullanılarak gerçekleştirilmemelidir. Sabit bölünme sonrasında eğitim örnekleriyle fit edilen herhangi bir dönüşüm doğrulama ve test örneklerine yalnızca transform olarak uygulanmalıdır. scikit-learn Pipeline yaklaşımı bu işlem sırasını güvence altına almak için uygun bir araçtır. CNN'nin sabit 0–16 piksel aralığını 16'ya bölerek normalleştirmesi ise veri üzerinden tahmin edilen bir ölçek parametresi gerektirmez. [2, 13, 20]

Farklı başlangıç tohumları, ağırlıkların ilk değerleri ve eğitim sürecindeki rastgeleliğin bir bölümünü kontrol etmeye yardımcı olur. Aynı tohum değerleri farklı donanım, sürücü veya kütüphane sürümlerinde birebir aynı çıktıyı garanti etmez. Bu araştırmanın ana deney, beş tohumlu kararlılık ve dokuz doğrulama eğitimi tek Google Colab oturumunda yürütülmüş; Python, TensorFlow, Keras ve scikit-learn sürümleri sonuç arşivine kaydedilmiştir.

Model seçimi doğrulama kaybının en düşük olduğu eğitim noktasına dayanır. Erken durdurma, uzun eğitim süreçlerinde doğrulama performansı kötüleşirken gereksiz epoch sayısını sınırlamaya yardımcı olur. En iyi ağırlıkların yeniden yüklenmesi, son epoch ağırlıklarının rastlantısal biçimde seçilmesini önler. Bu mekanizmaların birlikte kullanılması overfitting riskini azaltabilir; ancak test başarısı, doğrulama kaybı ve eğitim eğrilerinin incelenmesi hâlâ gereklidir.

Test performansını hesaplarken kullanılan bölünmenin değişmemesi özellikle önemlidir. Eğer modeller farklı test kümelerinde değerlendirilseydi aralarındaki küçük başarı farkları yöntem etkisi ile örnekleme etkisini aynı anda yansıtabilirdi. Burada aynı test gözlemleri üzerinde karşılaştırma yapılabildiğinden CNN–SVM çifti için eşleştirilmiş doğruluk durumu doğrudan analiz edilmiştir. McNemar testi, sadece toplam doğru sayılarından değil iki yöntemin aynı gözlemler üzerindeki uyuşmazlıklarından yararlanır. [14, 15, 16]

Veri bölünmesi hakkında raporlamanın amacı yalnızca toplam örnek sayısını bildirmek değildir. Aynı örneğin hem eğitim hem test kümesinde bulunmaması sağlanmalı, her bölünmedeki sınıf dağılımı makul düzeyde olmalıdır. Kayıtlı indeksler üzerinde yapılan bütünlük kontrolü, her gözlemin yalnızca bir bölünmede bulunduğunu doğrulamaktadır. Bu güvence yeni kararlılık deneyi için de önemlidir. Model aynı test kümesinde değerlendirildiğinden rastgeleliğin neden olduğu değişimler farklı test örneklerinin seçilmesiyle karıştırılmamaktadır. Bununla birlikte bir kişinin tüm örneklerini aynı bölünmede tutan grup tabanlı bir protokol uygulanıp uygulanmadığı mevcut arşivden doğrulanamaz.

Deney sonuçlarının hesaplanmasında etiket tahminleri ve tahmin olasılıkları farklı amaçlarla kullanılır. Doğruluk ve Macro F1 için her test örneğinin tahmin edilen sınıfı gerekirken ROC-AUC için sınıf olasılıklarının karşılaştırılması önemlidir. Bu nedenle model dosyalarının yanında tahmin CSV ve NumPy olasılık dosyalarının da saklanması, sonradan yapılan değerlendirmelerin yeniden üretilebilmesini sağlar. Farklı hesaplama kütüphanesi sürümleri küçük nümerik farklara yol açabildiğinden ortam bilgileri ayrıca korunmuştur. Bu yaklaşım, raporlanan bir yüzde değerinin kaynağını izlemeyi kolaylaştırır.

Klasik yöntemlerle CNN arasında eşit koşullar sağlanırken girdi biçimi zorunlu olarak farklılaşmaktadır. CNN görüntünün satır ve sütun düzenini korur; klasik sınıflandırıcıların çoğu ise tek boyutlu özellik vektörü bekler. Bu dönüşüm temel piksel bilgisini ortadan kaldırmaz, ancak uzamsal komşuluk ilişkilerinin açık biçimde işlenmesini değiştirir. Bu nedenle sonuçların tamamını yalnızca optimizasyon algoritmasına bağlamak doğru olmaz. Öğrenilen temsilin biçimi de değerlendirmeye dahil edilmelidir. Yöntemler bölümünde bu ayrımın belirtilmesi karşılaştırmanın kapsamını açıklaştırır.

Bir modelin kaydedilmiş ağırlıklarını yeniden yükleyerek tahmin elde etmek ile sıfırdan eğitimini tekrarlamak aynı şey değildir. Yeniden yükleme kayıtlı modelin değerlendirmesini doğrulayabilir,

ancak eğitim rastgeleliğinin etkisini göstermez. Beş seed çalışması bu ikinci soruya yanıt arar. Bunun için model her koşuda yeniden başlatılır, farklı seed ile eğitilir ve önceden belirlenen doğrulama kaybı ölçütüne göre saklanır. Sonuçlar daha sonra aynı test kümesinde değerlendirilir. Bu prosedürün açık biçimde belgelenmesi, sonucun neyi ölçtüğünü doğru tanımlar.

Ana deneyin son performans tablosu table_6_final_performance.csv, CNN kararlılık sonuçları all_five_runs.csv ve ek mimari karşılaştırmaları validation_summary.csv üzerinden alınmıştır. Şekiller, aynı Colab oturumunda kaydedilen sonuç ve eğitim geçmişlerinden hazırlanmıştır. Raporlama sırasında yeni model eğitimi gerçekleştirilmemiş veya test sonuçlarına bakarak en yüksek seed nihai model olarak seçilmemiştir.

Tablo 1. Eğitim, doğrulama ve test ayrımı

Veri ayrimi	Ornek sayisi
Training	1257
Validation	270
Test	270

Deneyin izlenebilirliği için eğitim, doğrulama ve test indeksleri ayrı bir dosyada saklanmıştır. Böylece farklı model aileleri arasında aynı örnekler üzerinden karşılaştırma yapılabilir. Sinir ağı eğitiminde en iyi epoch doğrulama kaybına göre seçildiğinden test kümesinin erken durdurma kararına katılması önlenir. Bununla birlikte test sonuçları görüldükten sonra başlatılan ek seed deneyleri yeni ve bağımsız bir test doğrulaması olarak yorumlanmamıştır. Bu deneylerin amacı sabit veri bölünmesi koşulunda eğitim rastgeleliğine duyarlılığı betimlemektir. Test kümesindeki örnekler aynı kaldığı için seed çalışmaları arasında hesaplanan ortalama, bağımsız beş ayrı veri toplama deneyinin yerini tutmaz.

4. Results

Tek Colab oturumunun ana deneyinde, doğrulama makro F1 ölçütüyle seçilen CNN-C'nin doğrulama doğruluğu %99,26, test doğruluğu %98,15 ve test makro F1 değeri %98,12 olarak hesaplanmıştır. RBF-SVM aynı test kümesinde %98,89 doğruluk ve %98,88 makro F1 göstermiştir. Lojistik regresyon %98,52, KNN %98,15, rastgele orman %97,41 ve Gradient Boosting %96,30 test doğruluğuna ulaşmıştır. Bu sıralama, testteki en yüksek skora bakılarak model seçiminin değiştirilmesini gerektirmez.

Eşleştirilmiş CNN ve SVM tahminlerinde yalnızca altı gözlem üzerinde iki modelin doğruluk durumu farklıdır: dört örnekte CNN yanlış SVM doğru, iki örnekte CNN doğru SVM yanlıştır. McNemar exact p değeri 0,6875 olup testte gözlenen farkın güçlü bir üstünlük kanıtı olmadığını göstermektedir. Bootstrap ile oluşturulan doğruluk farkı güven aralığı sıfırı kapsamaktadır.

CNN-C kararlılık deneyinde sabit veri ayrımı ve 101, 202, 303, 404, 505 tohumları kullanılmıştır. Test doğrulukları sırasıyla %98,15, %99,63, %97,04, %99,63 ve %99,26'dır. Ortalama %98,74; örnek standart sapması 1,13 yüzde puandır. En düşük test başarısı 303, en yüksek başarı ise 202 ile 404 koşularında gözlenmiştir. Bu çalışma aynı 270 test gözlemi üzerinde yürütülen bir kararlılık analizidir; beş bağımsız test veri kümesine karşılık gelmez.

Beş CNN-C koşusunun en iyi epoch değerleri sırasıyla 44, 37, 31, 23 ve 50 olmuştur. Ortalama doğrulama doğruluğu %99,11, doğrulama makro F1 değeri %99,11'dir. Test ortalaması doğrulama ortalamasından düşüktür; özellikle 303 koşusundaki %97,04 test doğruluğu sonuçların başlangıca duyarlılığını gösterir. Bu yüzden en iyi test skorunu tek başına öne çıkarmak yerine tüm koşular ve dağılımı sunulmalıdır.

Ana deneydeki CNN-C modelinin tek koşu test doğruluğu %98,15, kararlılık deneyinin beş koşulu için ortalama test doğruluğu %98,74'tür. Bu iki sayı farklı deney hedeflerine aittir: ilki doğrulama ile seçilen

ana modelin performansıdır, ikincisi sabit veri ayrımında rastgele başlangıca duyarlılığı özetler. Aynı test kümesi birden fazla kez kullanıldığından, kararlılık deneyindeki yüksek tekil skorlar bağımsız bir doğrulama veya kesin model iyileşmesi kanıtı değildir.

Ana deneyde Logistic Regression modelinin test doğruluğu %98,519, Random Forest modelinin test doğruluğu yaklaşık %97,407 olarak kaydedilmiştir. Bu değerler raporun model karşılaştırma tablosunda tüm diğer algoritmalarla birlikte sunulmaktadır. Doğrulama ve test skorları arasında bazı algoritmalarda farklı yönlerde değişim bulunması, tek bir ayrımdaki performans tahmininin mutlak bir sıralama oluşturmadığını gösterir. Özellikle az sayıda test gözlemi olan veri kümelerinde sonuçların nedenlerini model özellikleriyle birlikte yorumlamak gerekir. [19, 20]

CNN-C modelinin eğitim doğruluğu ana deneyde %100 olarak kaydedilmiştir. Aynı koşulda doğrulama doğruluğu %99,259 seviyesindedir. Eğitim-doğrulama farkının yaklaşık 0,741 yüzde puan olması dikkat çekici bir sorun görünümünde değildir. Ancak bu sayı tek başına öğrenme davranışını göstermez; kayıp fonksiyonunun eğrisi ve hata yapılan örneklerin dağılımı da gerekir. Bu nedenle raporda eğitim ve doğrulama kaybına ilişkin ek grafiğe yer verilmiştir.

Beş farklı başlangıçta yanlış sınıflandırma sayıları sırasıyla 5, 1, 8, 1 ve 2'dir. Özellikle 303 tohumuyla yapılan eğitimde sekiz hata bulunması, diğer koşulara göre daha düşük başarıya karşılık gelir. Bütün koşular aynı 270 test gözleminde değerlendirildiği için bu doğruluk oranları bağımsız test örneklemleri gibi ele alınamaz. Modelin eğitim rastgeleliğine tepkisini değerlendirmek için hem ortalama hem standart sapma hem de koşu bazlı tahminler birlikte paylaşılmıştır.

En düşük doğrulama kaybının görüldüğü en iyi epoch değerleri 23–50 arasında değişmektedir. Erken durdurma ve en iyi doğrulama kaybındaki ağırlıkların geri yüklenmesi aynı eğitim protokolünü korumuştur. Farklı tohumların test başarısı arasında gözlenen değişim, özellikle tek bir yüksek skoru genel başarı göstergesi olarak kullanmayı sakıncalı kılar. Donanım ve sürüm kayıtları ortam farklarının tekrar üretilebilirlik üzerindeki olası etkilerini incelemeyi kolaylaştırır.

Başarı karşılaştırmasında yüzdelerin yanında doğru ve yanlış tahmin sayılarının da verilmesi, özellikle küçük test kümelerinde yorum kolaylığı sağlar. Örneğin CNN-C'nin yüzde 98,148 başarısı 270 örneğin 265'ini doğru tahmin etmesine, SVM'nin yüzde 98,889 başarısı ise 267 örneği doğru tahmin etmesine karşılık gelir. Yaklaşık bir yüzde puanlık fark gibi görünen miktar gerçekte yalnızca iki örnektir. Dolayısıyla görsel grafiklerdeki sütun farklarını örnek sayısı bağlamından koparmamak gerekir. Bu açıklama istatistiksel karşılaştırmanın neden sonuç bölümüne eklendiğini de gösterir.

Kararlılık deneyinde en yüksek doğrulama doğruluğu 202 tohumunda %99,63; 303, 404 ve 505 tohumlarında en düşük oran %98,89'dur. Testte 202 ile 404 aynı en yüksek doğruluğa ulaşmış, 303 en düşük sonucu göstermiştir. Bu sıralamalar test başarısına göre yeni bir model seçildiği anlamına gelmez. Koşuların tamamı rapora alınmıştır; ortalama, standart sapma ve hata sayıları, değişimin görünür olmasını sağlamaktadır.

Öğrenme eğrileri raporda bağımsız bir sonuç türü olarak değerlendirilmelidir. Doğrulama kaybının bir süre azalıp daha sonra artması, bazı koşularda eğitim sürecinin durdurulmasını gerektiren bir işarettir. En iyi epoch değerlerinin koşular arasında farklılaşması, her eğitim için son epoch'u seçmenin aynı kalite ölçütünü sağlamayabileceğini göstermektedir. Checkpoint mekanizması sayesinde kaybı en düşük olan aşamanın ağırlıkları kullanılır. Bunun sonucunda bildirilen test skorları son eğitim adımının değil, doğrulama temelli belirlenen durumun performansını yansıtır.

Tüm sonuçların raporlanmasında daha büyük değerin otomatik olarak bilimsel üstünlük anlamına gelmediği esas alınmıştır. Yüzde olarak ifade edilen skorlar test gözlem sayısıyla birlikte okunmalıdır. Bunun yanında doğrulama performansı ayrı gösterilerek hangi ölçütün model seçimi için kullanıldığı anlaşılır hâle getirilmiştir. Farklı zamanlarda üretilmiş deneyler tek bir eğitim süreciymiş gibi sunulmamış, karşılaştırmanın sınırları açık biçimde korunmuştur.

Ek mimari/doğrulama çalışmasının dokuz eğitimi, üç mimarinin üçer başlangıç altında yalnızca doğrulama kümesinde değerlendirilmesinden oluşmaktadır. Ortalama doğrulama makro F1 değerleri güçlü düzenlileştirmede 0,99009, referansta 0,98890 ve küçük CNN'de 0,98761 olarak kaydedilmiştir. Bu sonuçlar ana model seçimini değiştirmek için kullanılmamış, ek keşifsel inceleme olarak sunulmuştur.

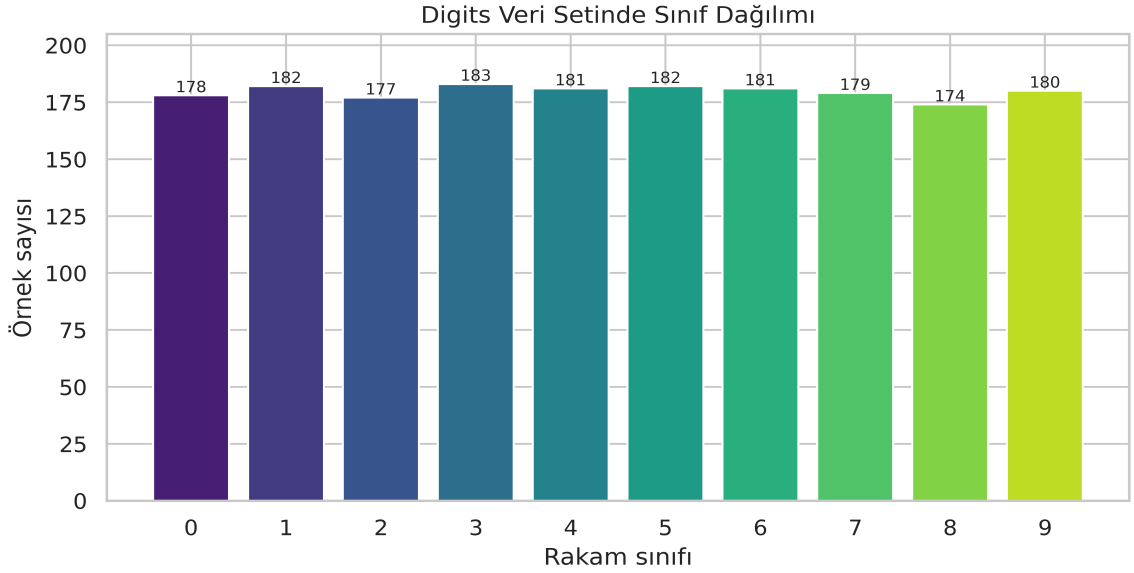
Tablo 2. Modellerin doğrulama ve test performansları

Model	Validation Acc %	Test Acc %	Test Macro F1 %
CNN (CNN-C Görüntü modeli	99.26	98.15	98.12
Logistic Regression	97.78	98.52	98.52
SVM (RBF)	97.41	98.89	98.88
Random Forest	96.67	97.41	97.38
KNN	96.30	98.15	98.15
Gradient Boosting	95.19	96.30	96.27

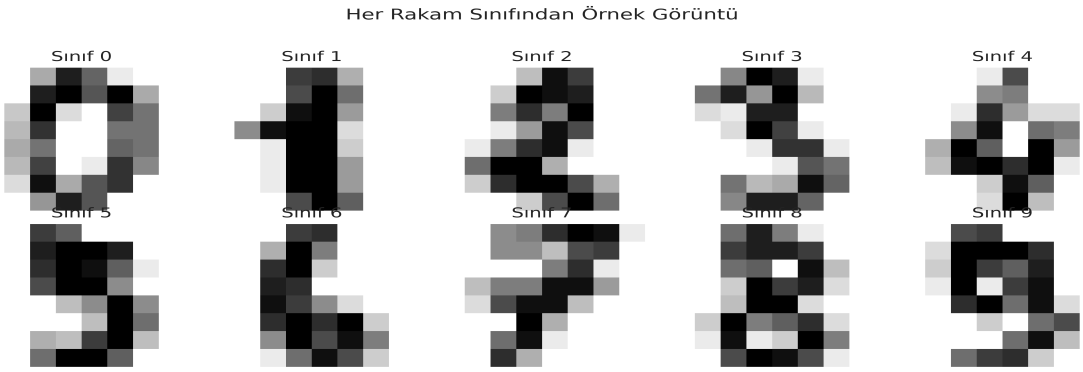
Tablo 3. CNN-C için beş tohumlu kararlılık deneyi

Seed	Best epoch	Test Acc %	Macro F1 %
101	44	98.15	98.18
202	37	99.63	99.63
303	31	97.04	96.93
404	23	99.63	99.63
505	50	99.26	99.24

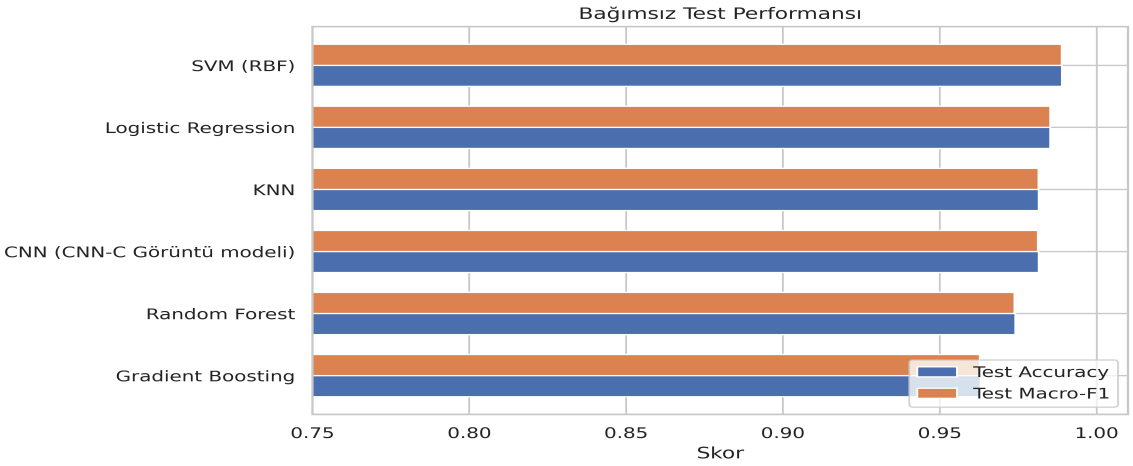
Tabloda verilen test yüzdeleri, sınırlı sayıdaki örneğe karşılık gelen tam sayı doğru tahminlerinden elde edilmektedir. Bu nedenle küçük ondalık yüzdelik farklar geniş ve genellenebilir bir üstünlük olarak yorumlanmamalıdır. Son beş-seed deneyinde bütün koşuların sonuçlarının birlikte sunulması, yalnızca en yüksek skoru veren koşunun raporlanmasından daha tutarlı bir özet sağlar. Seed sonuçları arasındaki değişkenlik, modelin başlangıç koşullarına göre verdiği yanıtı gösterir; farklı veri kümeleri veya farklı test ortamları üzerinde genelleme garantisi oluşturmaz. Önceden tanımlanan model seçimi ilkesi ile sonradan yapılan hata analizi bu nedenle ayrı değerlendirilmiştir. [15, 16, 17]



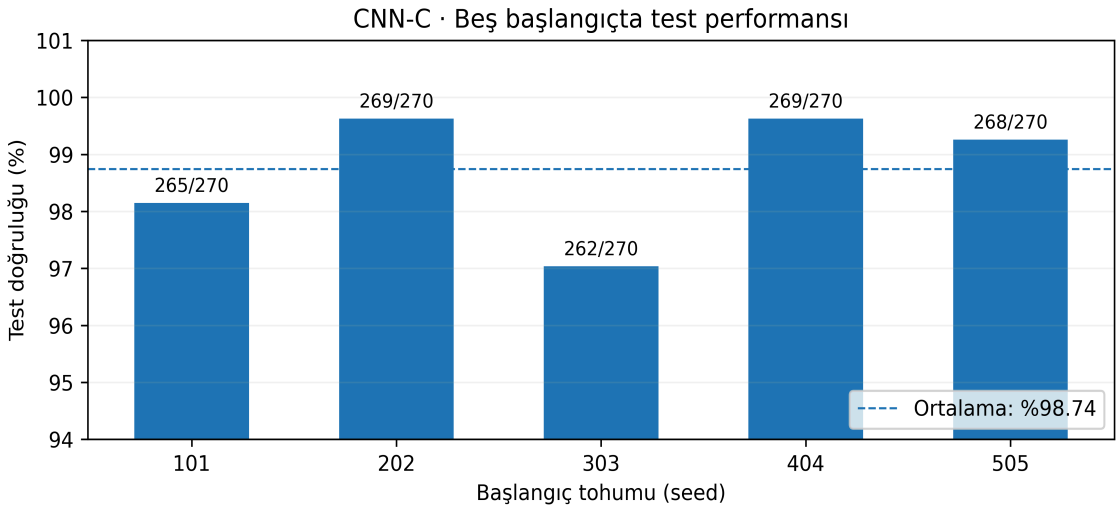
Şekil 1. Digits veri kümesinde sınıflara göre örnek sayıları.



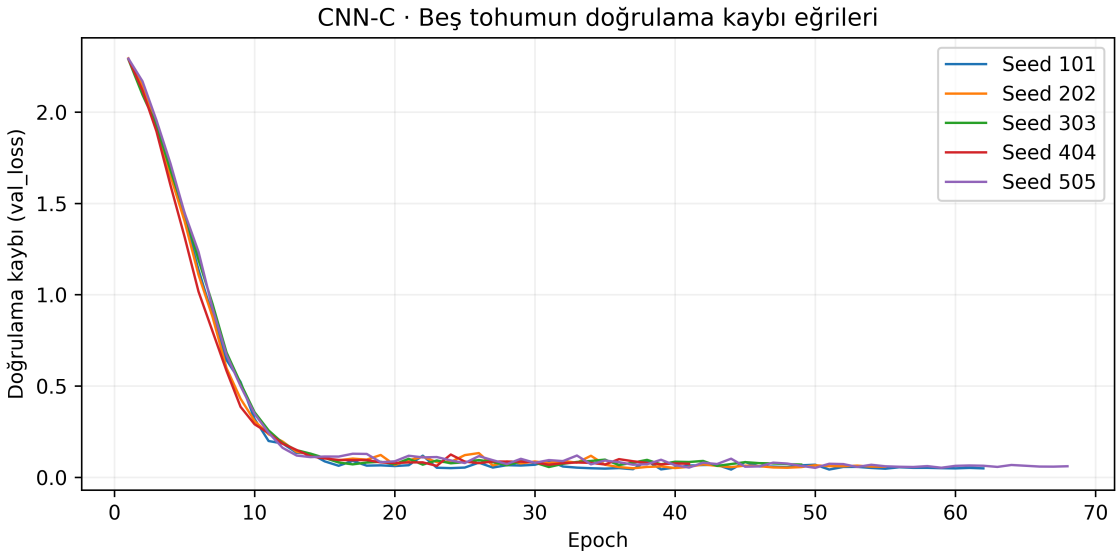
Şekil 2. Digits veri kümesinden örnek el yazısı rakam görüntüleri.



Şekil 3. Colab ana deneyinde modellerin test doğruluğu karşılaştırması.



Şekil 4. CNN-C için beş başlangıç tohumunda test doğruluğu.



Şekil 5. CNN-C kararlılık eğitimlerinde doğrulama kaybı eğrileri.

5. Discussion

Ana deneyde en yüksek doğrulama makro F1 değerini CNN-C elde ederken test doğruluğunda RBF-SVM az farkla öndedir. CNN-C 265, SVM 267 test örneğini doğru sınıflandırmıştır. McNemar testinde uyuşmazlıklar dört CNN-yanlış/SVM-doğru ve iki CNN-doğru/SVM-yanlış örnektir. Kesin p=0,6875 değeri bu testte istatistiksel üstünlük için yeterli kanıt oluşturmaz. Dolayısıyla test sonuçlarına bakıp doğrulama aşamasında seçilen modeli geriye dönük değiştirmek doğru olmaz.

Beş tohumlu Colab kararlılık deneyinde test doğruluğu ortalaması %98,74, örnek standart sapması 1,13 yüzde puandır; sonuçlar %97,04–%99,63 arasında değişmektedir. Bu aralık, sabit veri ayrımı altında bile başlangıç koşullarının ölçülen performansı etkileyebildiğine işaret eder. Beş koşu aynı test kümesini kullandığından bu değerler dış veri başarısının güven aralığı gibi değerlendirilmemelidir.

Overfitting değerlendirmesinde yalnızca test doğruluğuna bakmak yeterli değildir. Ana deneyde CNN'nin eğitim doğruluğu %100 ve doğrulama doğruluğu yaklaşık %99,259 olduğundan gözlenen fark yaklaşık 0,741 yüzde puandır. Bu küçük fark olumlu görünse de eğitim ve doğrulama loss eğrileri birlikte incelenmelidir. Kararlılık deneyinde doğrulama kaybının daha sonra artabilmesi nedeniyle erken durdurma ve doğrulama kaybı ölçütüne göre ağırlıkların geri yüklenmesi kritik rol oynar.

Bu araştırma küçük, standartlaştırılmış ve düşük çözünürlüklü bir veri kümesine dayanır. Gerçek dünya el yazısı fotoğraflarında ışık, arka plan, farklı görüntü çözünürlükleri ve dağılım kayması görülebilir. Dolayısıyla bildirilen yüksek doğruluk, gerçek hayattaki tüm el yazısı uygulamalarına doğrudan genellenemez. Ayrıca beş-seed deneyinden önce test sonuçlarının görülmüş olması, en iyi görünen yeni koşuyu bilimsel yöntem üstünlüğü olarak seçmeyi sakıncalı kılar.

Gözlenen SVM–CNN farkının yorumlanmasında iki önemli nokta öne çıkar. Birincisi, farkın yalnızca iki test örneğine karşılık gelmesidir. İkincisi ise her iki modelin farklı gözlemlerde hata yapabilmesidir. Bu nedenle modellerin toplam doğru sayıları kadar, hangi örneklerde ayrıştıkları da önem taşır. Eşleştirilmiş test bu sorunun daha uygun istatistiksel ifadesidir; elde edilen p değeri kesin bir üstünlük iddiasını desteklemez.

Beş CNN-C koşusunun çoğunda yüksek doğruluk elde edilmiştir; ancak %97,04'lük koşu, başlangıç değişkenliğinin yok sayılamayacağını göstermektedir. Sabit veri bölünmesi ile yapılan tekrarlar örnekleme etkisini değil eğitim sürecindeki rastgeleliğe duyarlılığı gözlemlemeye yarar. Bu test

kümesindeki yüksek performansın farklı kişiler, cihazlar ve gerçek dünya görüntüleri için korunup korunmadığı ise ayrı bir dış doğrulama çalışmasını gerektirir.

Ek doğrulama bölümünde üç CNN yapılandırması üçer başlangıçla karşılaştırılmıştır. Ortalama doğrulama çapraz entropi kaybı güçlü düzenlileştirmede 0,02876, referans yapıda 0,02909 ve küçük CNN'de 0,04231'dir. Güçlü düzenlileştirme ile referans arasındaki fark yalnızca yaklaşık 0,00033'tür; üçer tekrar üzerinden genel üstünlük ilan etmek uygun değildir. Bu denemelerde test kümesiyle yeni model seçimi yapılmamıştır.

Bir başka sınırlılık, veri setinin görüntülerinin yalnızca 8 × 8 olmasıdır. Düşük çözünürlük hem hesaplama açısından avantaj sağlar hem de daha karmaşık el yazısı örneklerindeki ince ayrıntıları ortadan kaldırabilir. Veri kümesinin standartlaştırılmış yapısı, mobil kamera üzerinden elde edilen düzensiz ve gürültülü görüntülerin karşılığı değildir. Üretim ortamı tasarlayan bir uygulama geliştiricisinin gerçek saha verisi toplamadan bu sonucu doğrudan ürün başarısı olarak değerlendirmemesi gerekir.

Son olarak bu karşılaştırmanın pedagojik değeri yalnızca hangi modelin yüzde olarak öne çıktığında değildir. Veri hazırlama, algoritmaların karşılaştırılması, doğrulamayla seçme, test sonucu raporlama, aşırı öğrenmeyi analiz etme ve tekrarlanabilir deney kaydı birlikte ele alınmıştır. Bu bütünlük, tek bir yüksek başarı sayısından daha güçlü bir akademik gerekçe sağlar ve sonraki çalışma tasarımlarında hangi belirsizlik kaynaklarının giderilmesi gerektiğini gösterir.

Bir araştırmanın sınırlarını açıkça belirtmek, elde edilen yüksek başarıyı değersizleştirmez; tam tersine sonucun hangi koşullarda geçerli olduğunu tanımlar. Buradaki sonuçlar Digits veri kümesinin 8 × 8 özellik gösterimi, kayıtlı eğitim-doğrulama-test ayrımı ve belirtilen kütüphane ortamı altında geçerlidir. Daha farklı cihazlardan toplanan gerçek el yazısı örnekleri, farklı çözünürlükler ve kullanıcı profilleri için aynı başarı oranlarının korunacağı çıkarımı yapılamaz. Bu nedenle modelin saha kullanımına uygunluğunu değerlendirmek ek deney tasarımı gerektirmektedir.

Sonuçların tekrarlanabilirliği yalnızca kodun açık olmasına değil, deney tanımlarının ve veri kaynaklarının yeterli açıklıkta olmasına bağlıdır. Bir okuyucunun hangi modelin hangi dosyadan geldiğini, hangi veri indeksleriyle eğitildiğini ve raporlanan metriklerin hangi tahminlerden hesaplandığını görebilmesi gerekir. Bu teslim kapsamında ana deneyin özgün arşivi, son kararlılık deneyinin özgün arşivi ve karşılaştırma tablosu ayrı tutulmuştur. Böylece farklı zamanlarda çalıştırılmış deneylerin sonuçları birbirine karıştırılmadan değerlendirilebilir.

Model başarısının farklı yönlerini ölçen metrikler bazen birbirine yakın sonuçlar verir. Accuracy ve Macro F1'in bu projede yakın olması tüm hataların önemsiz olduğu anlamına gelmez. Örneğin bazı rakamlar benzer biçimler taşıdığından hatalar küçük bir alt grupta yoğunlaşabilir. Böyle bir durumda karmaşıklık matrisleri ve sınıf bazında ölçümler, ortalama değerlerin saklayabildiği zayıflıkları ortaya çıkarır. Geliştirme kararları daha sonra alınacaksa bu ayrıntılar önemlidir; mevcut çalışmada ise test sonuçlarını izleyerek yeni bir model seçmekten özellikle kaçınılmıştır.

Sonuçta yüksek doğruluk, düşük kararlılık değişkenliği ve küçük genelleme farkı olumlu bulgulardır; fakat her biri yalnızca kendi ölçtüğü soruya cevap verir. Düşük seed değişkenliği farklı veri bölünmelerindeki başarıyı garanti etmez. Küçük eğitim-doğrulama farkı bütün overfitting türlerinin bulunmadığını kanıtlamaz. Yüksek test doğruluğu da modeller arasındaki küçük farkların istatistiksel açıdan anlamlı olduğu anlamına gelmez. Bu ayrımların korunması, akademik rapordaki temel değerlendirme mantığını oluşturur.

6. Conclusion

Aynı eğitim, doğrulama ve test bölünmesi altında birden fazla algoritma ailesi karşılaştırılmış, sinir ağının doğrulama aşamasındaki yüksek başarısına karşılık testte SVM için küçük bir avantaj

gözlenmiştir. Eşleştirilmiş karşılaştırma bu fark için istatistiksel üstünlük kanıtı sunmamıştır. Sonuçlar, model seçiminin test kümesinden ayrı yapılmasının önemini ortaya koymaktadır.

CNN-C'nin beş farklı başlangıçla Colab ortamında yeniden eğitilmesinde ortalama test doğruluğu %98,74, örnek standart sapması 1,13 yüzde puan olarak bulunmuştur. Farklı tohumlarda %97,04–%99,63 aralığı gözlendiğinden, tek bir başlangıçtaki yüksek performansın tüm eğitimleri temsil etmediği görülmüştür. Yeni dış veri üzerinde değerlendirme yapılmadan sonuçların gerçek el yazısı fotoğraflarına genellenmesi uygun değildir.

Bu çalışma, küçük ölçekli görüntü sınıflandırma problemlerinin dikkatli bir deney protokolüyle incelenebileceğini ortaya koymuştur. Başarılı modellerin test doğrulukları yüksek olsa da küçük örneklem ve ortak veri bölünmesi, sonuçların yorumlanmasında ihtiyat gerektirir. Makine öğrenmesi yöntemleri ile derin öğrenme yaklaşımının birlikte raporlanması, çok sayıda algoritma ailesi arasında adil bir karşılaştırmaya olanak sağlamıştır.

Gelecek bir çalışmada test kümesinin deney tasarımı tamamlanana kadar tamamen kapalı tutulması, sınıflandırıcıların daha geniş ve bağımsız veri üzerinde yeniden değerlendirilmesi ve farklı veri bölünmelerinin eklenmesi önerilir. Böyle bir protokol, rastgele başlangıç etkisi ile örnekleme etkisini ayırmaya ve değişen görüntü koşullarında modellerin gerçekten ne kadar kararlı olduğunu araştırmaya yardımcı olacaktır.

Sonuçların en güçlü yanı, farklı öğrenme yaklaşımlarının aynı değerlendirme koşullarında ele alınması ve ek CNN deneyinin tüm koşularla birlikte kaydedilmesidir. Böylece gözlenen performans farkları model ailesi, rastgele başlangıç ve değerlendirme ayrımı bağlamında daha doğru yorumlanabilmektedir. Araştırmanın temel sonucu bir algoritmanın kesin üstünlüğü değil, model seçimi ve güvenilir raporlamanın birlikte yürütülmesinin gerekli olduğudur.

Deneyin daha ileri bir sürümü için önce yeni değerlendirme planı kayıt altına alınmalı, ardından modeller geliştirilip son aşamada daha önce incelenmemiş veri üzerinde değerlendirilmelidir. Böyle bir yaklaşım test kümesine aşırı uyum riskini azaltır. Çalışmanın mevcut hali öğrenme sürecinde kurulan yöntemsel disiplini ortaya koyarken, üretime dönük genelleme konusunda temkinli kalmaktadır.

Sonuçların değerlendirilmesinde hem test başarısının hem de uygulanan seçim protokolünün önemi ortaya çıkmaktadır. Modelin başarısı hakkındaki en güçlü yorum, tekil en yüksek skor yerine karşılaştırmanın kapsamı ve belirsizlikleri açıkça belirtilerek yapılabilir. Sabit test kümesindeki başarı, dış veri üzerinde bağımsız doğrulama yapılmadan gerçek kullanım başarısına eşitlenmemelidir.

References

[1] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. Proceedings of the IEEE, 86(11), 2278–2324.

[2] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

[3] Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20, 273–297.

[4] Breiman, L. (2001). Random forests. Machine Learning, 45, 5–32.

[5] Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. Annals of Statistics, 29(5), 1189–1232.

[6] Cover, T., & Hart, P. (1967). Nearest neighbor pattern classification. IEEE Transactions on Information Theory, 13(1), 21–27.

[7] Cox, D. R. (1958). The regression analysis of binary sequences. Journal of the Royal Statistical Society: Series B, 20(2), 215–242.

[8] Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. Nature, 323, 533–536.

[9] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. Advances in Neural Information Processing Systems, 25.

[10] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. Journal of Machine Learning Research, 15, 1929–1958.

[11] Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. Proceedings of ICML, 448–456.

[12] Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. Proceedings of ICLR.

[13] Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. Proceedings of IJCAI, 1137–1143.

[14] Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. Neural Computation, 10(7), 1895–1923.

[15] McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. Psychometrika, 12, 153–157.

[16] Efron, B., & Tibshirani, R. J. (1993). An introduction to the bootstrap. Chapman & Hall/CRC.

[17] Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. Information Processing & Management, 45(4), 427–437.

[18] Fawcett, T. (2006). An introduction to ROC analysis. Pattern Recognition Letters, 27(8), 861–874.

[19] Varoquaux, G. (2018). Cross-validation failure: Small sample sizes lead to large error bars. NeuroImage, 180, 68–77.

[20] Cawley, G. C., & Talbot, N. L. C. (2010). On over-fitting in model selection and subsequent selection bias in performance evaluation. Journal of Machine Learning Research, 11, 2079–2107.

[21] Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 32.

[22] Abadi, M., et al. (2016). TensorFlow: A system for large-scale machine learning. Proceedings of OSDI, 265–283.

Yapay zekâ kullanımı beyanı

Bu çalışmada üretken yapay zekâdan kod taslağı oluşturma ve düzenleme, hata giderme, sonuç kontrolü, akademik metin taslağı ve dil düzenlemesi aşamalarında yararlanılmıştır. Sayısal bulgular ve grafikler 17 Ekim 2026 tarihli Google Colab eğitim kayıtlarından alınmıştır; model eğitimleri yapay zekâ yanıtlarından türetilmemiştir. Son teslimin akademik sorumluluğu, kullanılan yöntemin anlaşılması ve kaynakların uygun kullanımının kontrolü öğrenciye aittir.

Kod ve veri bağlantıları

Veri kümesi: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html

GitHub kod deposu: https://github.com/ReyhanOnbasi/El-Yazisi-Rakam-Siniflandirma